

Deep Learning for Medical Image Analysis / Medical NLP


Titipat Achakulvisut
SuperAI June 3, 2025



มหาวิทยาลัยมหิดล
Mahidol University



Biomedical
and Data Lab
Mahidol University





Quick introduction

Biomedical and Data Lab @ Mahidol University


Biomedical and Data (Bio-Dat) lab at Mahidol University runs by Titipat Achakulvisut. Our lab work in an intersection of applied natural language processing, machine learning, and science of science. We aim to build tools to make better science. We also broadly interested in ML applications for bioengineering and biomedical science.

Science of Science | Applied Natural Language Processing | Applied Machine Learning

Research



<https://biodatlab.github.io/>



Thonburian Whisper

Pubmed Parser: A Python Parser for PubMed Open-Access XML Subset and MEDLINE XML Dataset

License MIT JOSS 10.21105/joss.01979 DOI 10.5281/zenodo.3660006 Build Status

Pubmed Parser is a Python library for parsing the [PubMed Open-Access \(OA\) subset](#), [MEDLINE XML](#) repositories, and [Entrez Programming Utilities \(E-utils\)](#). It uses the [lxml](#) library to parse this information into a Python dictionary which can be easily used for research, such as in text mining and natural language processing pipelines.

Overview of Medical Image / Medical NLP

- Image tasks:

- Classification แบ่งประเภทภาพถ่ายทางการแพทย์ เช่น การแบ่งประเภทภาพ X-ray
- Segmentation ดึง pixels ที่สนใจออกจากภาพ เช่น การ highlight เซลล์จากภาพ
- Object Detection หาดำแหน่งจากภาพ เช่น ตำแหน่งของก้อนเนื้อในตับ
- Image-text เช่น ใส่ภาพและสร้างคำบรรยายจากภาพ
 - เช่น การอธิบายภาพ X-ray → มี Start-ups ในไทยที่ทำหลายเจ้า

- NLP tasks:

- Classification แบ่งประเภทข้อความ
- Question Answering ตอบคำถาม
- Summarization สรุปใจความ
- Language Generation สร้าง text ใหม่ขึ้นมา

Image Modalities


- Image Modalities

- CT
- MRI
- X-ray
- Pathology
- Ultrasound
- Fundus
- Endoscope
- Dermoscopy
- OCT


แต่ละ modalities นำมาใช้งานใน
สถานการณ์ไม่เหมือนกัน

Note: simple solution บางครั้งดีกว่า
สำหรับแพทย์, solution ไม่จำเป็นต้องทำ
งานเหมือนแพทย์

"COVID-19 infection in chest CT"




"Lower-grade glioma in brain MRI"



"COVID-19 infection in chest X-Ray"



"Glandular structure in colon Pathology"




"Malignant tumor in breast Ultrasound"




"Optic disc in retinal Fundus"




"Neoplastic polyp in colon Endoscope"



"Melanoma in skin Dermoscopy"



"Cystoid macular edema in retinal OCT"



Brief timelines

- Deep learning เริ่มเข้ามามีบทบาทใน Medical Image Analysis
 - [2013 - now] Pre-trained Convolution Neural Network (CNN)
→ ใช้ใน tasks หลักๆ เช่น Image classification, Semantic Segmentation, Object detection, Image reconstruction, Deep learning ชะงักเกือบทุก tasks ข้างต้นและกลายเป็นโมเดลที่ใช้แพร่หลาย
 - [2017 - now] Transformers → หลังจากที่ข้อมูลเริ่มมีการ scale มากขึ้น Transformers ทำงานได้ดีมากขึ้นและถูกนำมาใช้มากขึ้น

เทรนดีเทรนโมเดลด้วย data ที่มากขึ้น

- [2020 - now] Early Multimodal Model → เริ่มนำ modalities มารวมกัน เช่น CLIP
- [2022 - now] Large Language Model (LLM) → เริ่มตอบคำถามทางด้านการแพทย์ได้ดี
- [2023 - now] Multimodal LLM → ยุคปัจจุบันที่นำ modality ต่างๆมารวมกับ LLM

Brief timelines

- Deep learning เริ่มเข้ามามีบทบาทใน Medical Image Analysis
 - [2013 - now] Pre-trained Convolution Neural Network (CNN)
→ ใช้ใน tasks หลักๆ เช่น Image classification, Semantic Segmentation, Object detection, Image reconstruction, Deep learning ชะงักเกือบทุก tasks ข้างต้นและกลายเป็นโมเดลที่ใช้แพร่หลาย
 - [2017 - now] Transformers → หลังจากที่ข้อมูลเริ่มมีการ scale มากขึ้น Transformers ทำงานได้ดีมากขึ้นและถูกนำมาใช้มากขึ้น


เทรนดีเทรนโมเดลด้วย data ที่มากขึ้น

- [2020 - now] Early Multimodal Model → เริ่มนำ modalities มารวมกัน เช่น CLIP
- [2022 - now] Large Language Model (LLM) → เริ่มตอบคำถามทางด้านการแพทย์ได้ดี
- [2023 - now] Multimodal LLM → ยุคปัจจุบันที่นำ modality ต่างๆมารวมกับ LLM


Pretrained Models

Classification

- Pretrained CNN Models เริ่มถูกนำมาใช้งานแพร่หลายใน Computer vision
- “Dermatologist-level classification of skin cancer with deep neural networks” เป็นงานจากทีม Stanford และเป็นงานแรกๆที่ CNN นำมาใช้ทางการแพทย์คือการ fine-tune CNN เพื่อตรวจโรคผิวหนัง (2017)
- ใช้ Inception v3 ฝึกฝนด้วยภาพ **129,450 ภาพ / 2032 classes** → evaluate เทียบกับแพทย์ 21 คน (board-certified)
- Key message: ทำงานได้ดีกว่าแพทย์ board-certified




A. Esteva *et al.*, "Dermatologist-level classification of skin cancer with deep neural networks," *Nature*, vol. 542, no. 7639, pp. 115–118, Jan. 2017, doi: 10.1038/nature21056.



Classification

- “Cardiologist-level arrhythmia detection and classification in ambulatory electrocardiograms using a deep neural network” เป็นงานจาก Stanford เช่นกัน (Andrew Ng) ใช้ CNN เช่นเดิม และข้อมูลขนาดใหญ่ในการเทรนโมเดล
- 12 rhythm classes, **91232 single-lead ECGs, คนไข้ 53k คน** → ชนะ expert human interpretation



A. Hannun *et al.*, "Cardiologist-level arrhythmia detection and classification in ambulatory electrocardiograms using a deep neural network," *Nature Medicine*, vol. 25, no. 1, pp. 65–69, Jan. 2019, doi: 10.1038/s41591-018-0268-3.

Classification

- CheXpert is a large dataset of chest X-rays and competition for automated chest x-ray interpretation มีข้อมูล ~ 223k ภาพ
- Deep AUC Maximization (DAM) ใช้ pretrained model แต่ปรับ loss ด้วย AUC Score
- Backbone ใช้ EfficientNet family เป็นโมเดลหลัก
- โมเดลนี้ได้อันดับ 1 ของการแข่งขัน CheXpert

Appendix J. A Two-stage Training Framework for DAM






Figure 8: A Two-stage Deep AUC Maximization Framework. For the pretraining stage, we focus on learning representation by optimizing a standard CrossEntropy loss. For the AUC maximization stage, we focus on finetuning the decision boundary of classifier by optimizing AUC margin loss.

Semantic Segmentation

- Semantic Segmentation เป็น task ที่เราแบ่ง pixel เป็นประเภทต่างๆ
- ก่อนที่ Deep learning จะเข้ามาใช้ใน task ต่างๆมีการใช้ traditional machine learning มาก่อน เช่น Semantic Segmentation ใช้ Watershed algorithm หลักการใช้การเติมน้ำในภาพเพื่อแบ่ง pixels ให้แยกออกจากกัน



UNet for Semantic Segmentation

- U-Net (2015) เป็น CNN architecture ออกแบบมาสำหรับ semantic segmentation
- U-Net ชนะเทคนิคเดิมแบบขาดลอยในปีเดียวกัน ใน ISBI cell tracking competition → คนนำไปทดลองแล้วดีจริง





Fig. 4. Result on the ISBI cell tracking challenge. (a) part of an input image of the “PhC-U373” data set. (b) Segmentation result (cyan mask) with manual ground truth (yellow border) (c) input image of the “DIC-HeLa” data set. (d) Segmentation result (random colored masks) with manual ground truth (yellow border).

Table 2. Segmentation results (IOU) on the ISBI cell tracking challenge 2015.

Name	PhC-U373	DIC-HeLa
IMCB-SG (2014)	0.2669	0.2935
KTH-SE (2014)	0.7953	0.4607
HOUS-US (2014)	0.5323	-
second-best 2015	0.83	0.46
u-net (2015)	0.9203	0.7756

Pretrained UNet

- UNet ถูกพัฒนามาเรื่อยๆ และมี variants มากมาย – หนึ่งใน tools ที่ใช้งานง่ายและเทรนโมเดลได้สะดวก เช่น nnUNet
- nnUNet ถูกนำมาใช้ในการสร้าง TotalSegmentator (2024) แบ่ง 80 anatomical structures, 1143 examinations (616 MRIs, 527 CTs)





Figure 3. Overview of supported anatomical structures



UNet for coronary segmentation

1. Coronary segmentation




CT Angiogram



Segmentation



2. Plaque types and stenosis degree prediction



Classification

Straighten CPR




Degree Stenosis (ตีบ) / Plaque Type (ตะกั่ว)

UNet as Autoencoder


- นอกจากนั้น UNet ยังสามารถนำมาทำเป็น Autoencoder model ได้เช่นกัน

Principal Component Analysis (PCA)





Autoencoder

- Similar to PCA but we use the model to map:
defective skull $\rightarrow$ healthy skull
- **3DUNet** can be used as **autoencoder**
- Good performance and reasonable model size (260M params)





UNet as Autoencoder: CraNext



- เปลี่ยนจาก Convolution block ใน UNet เป็น ConvNeXt block
- เพิ่มประสิทธิภาพการสร้างกระดูกจาก kernel size ที่กว้างขึ้น, ลด parameters ~ 8 เท่า

Thathapatt Kesornsri et al., "CraNeXt: Automatic Reconstruction of Skull Implants With Skull Categorization Technique," IEEE Access, vol. 12, pp. 84907–84922, Jan. 2024, doi: <https://doi.org/10.1109/access.2024.3415173>. Available: <https://ieeexplore.ieee.org/document/10559595>. [Accessed: Jun. 01, 2025]

Transformers

- Vision Transformer ใช้ architecture ที่ล้อมาจาก NLP field โดยเปลี่ยนรูปเป็น Embeddings (Patch เล็ก ๆ กับตำแหน่งรูป) เพื่อเพิ่ม Global context




Figure 4: Architecture of the Vision Transformer (*on the left*) and details of the Vision Transformer encoder block (*on the right*). Vision transformer first splits the input image into patches and projects them (after flattening) into a feature space where a transformer encoder processes them to produce the final classification output.

Transformers + UNet

- งานวิจัยช่วงหลังนำ Transformers มาประยุกต์ใช้กับภาพถ่ายทางการแพทย์
- TransUNET (2021) เอา Transformer มาผสมกับ U-NET แบบ skip-connection พบว่าผลลัพธ์ดีกว่า Vision Transformer อย่างเดียว หรือ CNN อย่างเดียว
- ฝึกฝนด้วย MICCAI 2015 Multi-Atlas Abdomen ~ 3,700 CT scans





Fig. 1: Overview of the framework. (a) schematic of the Transformer layer; (b) architecture of the proposed TransUNET.



Object detection

- Object detection ทางกรแพทย์ มีเทรนด์การนำมาใช้ คล้ายกับการนำ Pretrained CNN models มาใช้
- โมเดล เช่น RCNN, YOLO ใช้ข้อมูล เช่น Microsoft COCO ในการ pretrain → จากนั้นนำมา fine-tune ใน task ทางกรแพทย์





FIGURE 3. YOLOv1 network architecture [48].

The YOLO timeline



Object detection with Transformers

- DETR ประยุกต์ใช้ transformers encoder-decoder สำหรับ object detection
- Backbone: CNN → Transformer encoder → Transformer decoder → Feed forward NN











Fig. 2: DETR uses a conventional CNN backbone to learn a 2D representation of an input image. The model flattens it and supplements it with a positional encoding before passing it into a transformer encoder. A transformer decoder then takes as input a small fixed number of learned positional embeddings, which we call *object queries*, and additionally attends to the encoder output. We pass each output embedding of the decoder to a shared feed forward network (FFN) that predicts either a detection (class and bounding box) or a “no object” class.

Object detection: Parasitic Egg Cells (2022)





Object detection: Parasitic Egg Cells



Object detection: Parasitic Egg Cells


DeepMAC

Ground truth
Bounding Boxes
for **11** Classes of
Egg Cells




Ref - Birodkar, Vighnesh, et al. "The surprising impact of mask-head architecture on novel class segmentation." *Proceedings of the IEEE/CVF International Conference on Computer Vision*. 2021

Building The Ensemble



(a) Two-stage Faster R-CNN



(b) One-stage RetinaNet

Ref: <https://www.mdpi.com/2072-4292/13/1/89>

Building The Ensemble

State-of-the-art one stage detectors and their mAP scores on Coco-Test-Dev

Method	Reference	Backbone	AP	AP ₅₀	AP ₇₅	AP _S	AP _M	AP _L
RetinaNet	ICCV17	ResNet-101	39.1	59.1	42.3	21.9	42.7	50.2
FoveaBox	-	ResNet-101	40.6	60.1	43.5	23.3	45.2	54.5
FCOS w/ imprv	ICCV19	ResNet-101	43.0	61.7	46.3	26.0	46.8	55.0
Noisy Anchor	CVPR20	ResNet-101	41.8	61.1	44.9	23.4	44.9	52.9
MAL	CVPR20	ResNet-101	43.6	62.8	47.1	25.0	46.9	55.8
SAPD	CVPR20	ResNet-101	43.5	63.6	46.5	24.9	46.8	54.6
ATSS	CVPR20	ResNet-101	43.6	62.1	47.4	26.1	47.0	53.6
PAA	ECCV20	ResNet-101	44.8	63.3	48.7	26.5	48.8	56.3
GFL	NeurIPS20	ResNet-101	45.0	63.7	48.9	27.2	48.8	54.5
TOOD	-	ResNet-101	46.7	64.6	50.7	28.9	49.6	57.0

GFL - **G**eneralized **F**ocal **L**oss (Li et al., 2020)

TOOD - **T**ask aligned **O**ne-stage **O**bject **D**etection (Feng et al., 2021)

Building The Ensemble

Backbone	Head	Number of stages	Region Proposal Network	Prediction tasks
ResNet-101	GFL ¹	1	No	BBoxes
ResNet-101	TOOD ²	1	No	BBoxes
ResNet-101	CascadeRCNN ³	2	Yes	BBoxes
HRNet	HTC ⁴	2	Yes	BBoxes + Instance Masks
ResNeXt-101	HTC ⁴	2	Yes	BBoxes + Instance Masks

¹Li, Xiang, et al. "Generalized focal loss: Learning qualified and distributed bounding boxes for dense object detection." *Advances in Neural Information Processing Systems* 33 (2020): 21002-21012.

²Feng, Chengjian, et al. "Tood: Task-aligned one-stage object detection." *2021 IEEE/CVF International Conference on Computer Vision (ICCV)*. IEEE Computer Society, 2021.


³Cai, Zhaowei, and Nuno Vasconcelos. "Cascade r-cnn: Delving into high quality object detection." *Proceedings of the IEEE conference on computer vision and pattern recognition*. 2018.

⁴Chen, Kai, et al. "Hybrid task cascade for instance segmentation." *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*. 2019.


Number of predictions @ Different prediction score thresholds

Predictions with scores ≥ 0.5


On test set with 2,200 images





Number of predictions @ Different prediction score thresholds



Number of predictions @ Different prediction score thresholds



Qualitative results on challenging samples



gfl-r101




tood-r101




cascade-rcnn-r101



htc-hrnet







htc-x101



ensemble





gfl-r101

Enterobius vermicularis (0.90)




tood-r101

Enterobius vermicularis (0.94)



cascade-rcnn-r101

Enterobius vermicularis (0.99)




htc-hrnet

Enterobius vermicularis (0.99)




htc-x101

Enterobius vermicularis (0.99)



ensemble

Enterobius vermicularis (0.96)



Training and results

- Batch size = 8, Optimizer = SGD, Learning rate = 0.02, HRNet width = 32
- Shortest side = 800, Longest side = 1333
- GPU 2-4 A100 mixed-precision mode (renting)
- Ensemble: Weighed box fusion (WBF), Non-maximum suppression = 0.5, Box threshold = 0.44

TABLE I
FINAL MODEL PERFORMANCES AND COMPUTATIONAL COMPLEXITIES

Model	mAP	AP ₅₀	AP ₇₅	AP _M	AP _L	mIoU	GFLOPs	# Parameters (Millions)
ResNet-101-GFL	0.941	0.998	0.992	0.891	0.941	0.923	215.69	52.33
ResNet-101-TOOD	0.948	0.998	0.993	0.897	0.948	0.926	179.85	53.24
HRNetV2p-W32-CascadeRCNN	0.948	0.999	0.993	0.9	0.948	0.927	312.83	74.71
HRNetV2p-W32-HTC (Multitask)	0.940	1.0	0.998	0.896	0.939	0.928	470.47	82.72
ResNeXt-101-HTC (Multitask)	0.941	1.0	0.999	0.898	0.941	0.928	629.3	139.83
Ensembled Model	0.956	0.998	0.993	0.916	0.957	0.934	-	-

*Our results show that a single multitask HRNetV2p-W32 model trained with pseudomasks gives the highest mIoU score with less model complexity. Combining ensembling boxes using weighted boxes fusion (WBF) and pseudo-label generation gives the highest performance on the leaderboard.

*AP scores are calculated on the validation set, AP₅₀ means average precision when IoU is greater than 50%, AP_M means average precision when the size of annotation is medium.


*mIoU scores are from the official scoreboard.

*Multitask means the model is trained with additional pseudomasks.

Early Multimodal Deep Learning

นอกจากนั้น Computer Vision มี task ที่ทำกันมายาวนานคือการอธิบายภาพด้วยภาษาเขียน ~ ปี 2015 มีการนำ Deep learning มาใช้ในการบรรยายภาพ

- **CNN-LSTM** → ใช้ CNN ในการดึง abstraction ออกจากภาพ จากนั้นใส่ให้ LSTM เพื่อบรรยายออกมาเป็น text tokens
 - คล้ายกับ Multimodal-LLM ปัจจุบัน แต่ว่า encoder = CNN, decoder = LSTM ไม่ใช่ Large Language Model (LLM)
- RCNN (Detection) → object ในภาพ, นำมา align กับคำ → สร้างเป็นประโยค



Early Multimodal Deep Learning

นอกจากนั้น Computer Vision มี task ที่ทำกันมายาวนานคือการอธิบายภาพด้วยภาษาเขียน โดย

- CNN-LSTM → ใช้ CNN ในการดึง abstraction ออกจากภาพ จากนั้นใส่ให้ LSTM เพื่อบรรยายออกมาเป็น text tokens
 - คล้ายกับ Multimodal-LLM ปัจจุบัน แต่ว่า encoder = CNN, decoder = LSTM ไม่ใช่ Large Language Model (LLM)
- **RCNN (Detection)** → object ในภาพ, นำมา align กับคำ → สร้างเป็นประโยค




Figure 2: Computing the Fragment and image-sentence similarities. **Left:** CNN representations (green) of detected objects are mapped to the fragment embedding space (blue, Section 3.2). **Right:** Dependency tree relations in the sentence are embedded (Section 3.1). Our model interprets inner products (shown as boxes) between fragments as a similarity score. The alignment (shaded boxes) is latent and inferred by our model (Section 3.3.1). The image-sentence similarity is computed as a fixed function of the pairwise fragment scores.

Data Data Data

Multimodal Deep Learning - CLIP (2021)

- CLIP (2021) เป็นโมเดล self-supervised ที่ใช้ contrastive learning เทรนให้เข้าใจภาพและข้อความจาก internet โดยไม่ต้องใช้ label แบบ traditional classification
- CLIP ใช้ **batch size ขนาดใหญ่ 32768 ภาพ**, เทรนด้วยข้อมูลภาพจาก Internet ~ **400M (image, text) pairs**




Figure 1. Summary of our approach. While standard image models jointly train an image feature extractor and a linear classifier to predict some label, CLIP jointly trains an image encoder and a text encoder to predict the correct pairings of a batch of (image, text) training examples. At test time the learned text encoder synthesizes a zero-shot linear classifier by embedding the names or descriptions of the target dataset's classes.

CLIP

- CLIP สามารถนำมาใช้ classify แบบ zero-shot ได้เลย
- เริ่มเห็นความสามารถในการ scale ของโมเดลด้วยข้อมูลจำนวนมาก






Figure 13. Zero-shot CLIP is much more robust to distribution shift than standard ImageNet models. (Left) An ideal robust model (dashed line) performs equally well on the ImageNet distribution and on other natural image distributions. Zero-shot CLIP models shrink this “robustness gap” by up to 75%. Linear fits on logit transformed values are shown with bootstrap estimated 95% confidence intervals. (Right) Visualizing distribution shift for bananas, a class shared across 5 of the 7 natural distribution shift datasets. The performance of the best zero-shot CLIP model, ViT-L/14@336px, is compared with a model that has the same performance on the ImageNet validation set, ResNet-101.

Biomed-CLIP (2024)

- Biomed-CLIP (Microsoft, 2024) ใช้ภาพจาก PMC-15M ทั้งหมด 15M image-text pairs → แบ่งเป็น subsets จำนวน 45M pairs, เทรนด้วย CLIP โดยมี ViT-B/16 เป็น image encoder, PubMedBERT เป็น text encoder



Biomed-CLIP

Details of creating PMC-15M

PubMed Central Open Access Subset (PMC-OA) [46] contains 4.4 million publicly available full-text articles (as of June 15, 2022). We download PMC-OA from ncbi.nlm.nih.gov/pmc/tools/ftp/#indart and extract complete packages for articles that include XML, PDF, media, and supplementary materials. We use PubMed Parser [47] to parse the XML files and extract captions and the corresponding figure references, along with PMID and PMCID of the provenance articles. This processing results in JSON objects stored in JSONL format, where each line represents one article, for convenient post-processing. Articles without figure references, or with incorrectly formatted XML files with syntax errors or missing information errors are ignored. After this clean-up, we collect 15 million figure-caption pairs (PMC-15M) from over 3 million distinct articles.

Pubmed Parser: A Python Parser for PubMed Open-Access XML Subset and MEDLINE XML Dataset

License [MIT](#) JOSS [10.21105/joss.01979](#) DOI [10.5281/zenodo.3660006](#)  [Build Status](#)


Pubmed Parser is a Python library for parsing the [PubMed Open-Access \(OA\) subset](#), [MEDLINE XML](#) repositories, and [Entrez Programming Utilities \(E-utils\)](#). It uses the `lxml` library to parse this information into a Python dictionary which can be easily used for research, such as in text mining and natural language processing pipelines.

For available APIs and details about the dataset, please see our [wiki page](#) or [documentation page](#) for more details. Below, we list some of the core functionalities and code examples.


← Open sourcing tool could help!

ELIXR-C

- ข้อมูล 1M CXR จาก 6 โรงพยาบาล: India, Illinois, Beth Israel, NIH, Stanford
- เทรนด้วย CLIP (Image encoder: SupCon, Text Encoder: T5)
- ทดลองใช้ zero-shot และวัดผลด้วย Precision@5 และ task อื่นๆ เช่น semantic similarity (ดึงภาพด้วยประโยค), Q-A



ELIXR-C Training



QA, Remove Major Finding
(Correct)



Stable appearance of right-sided pleural effusion. Pneumothorax has resolved.


Is the report inaccurate and need to be edited before being signed off?




Yes. There is a right pneumothorax. It has not resolved.

Segment Anything Model – SAM (2023)


- SAM ใช้ข้อมูล **11M ภาพ ที่มี segmentation mask ~ 1 billion masks**
- SAM ใช้ในการทำ zero-shot segmentation ได้คล้ายกับโมเดลอื่นๆที่สร้างด้วยข้อมูลขนาดใหญ่



(a) **Task:** promptable segmentation



(b) **Model:** Segment Anything Model (SAM)





(c) **Data:** data engine (top) & dataset (bottom)

Figure 1: We aim to build a foundation model for segmentation by introducing three interconnected components: a promptable segmentation *task*, a segmentation *model* (SAM) that powers data annotation and enables zero-shot transfer to a range of tasks via prompt engineering, and a *data* engine for collecting SA-1B, our dataset of over 1 billion masks.



Transformers: MedSAM (2024)

- Fine-tuning SAM ด้วย 1 ล้านเซตข้อมูลที่ประกอบด้วย **Image และ Mask** ซึ่งครอบคลุม 10 modalities ข้อมูลมาจากหลายแหล่งมาก เช่น AbdomenCT-1K, COVID-19-CT-Seg, TotalSegmentator, ...
- MedSAM segment ออกมาได้ดีขึ้น และมีความสามารถในการ segment สิ่งที่ไม่เคยถูกเทรนมาก่อนมากกว่าโมเดลอื่น ๆ รวมทั้ง segment modalities ที่ไม่ได้เทรนมาก่อนได้ดีกว่า
- นำไปใช้ในการช่วยแพทย์ annotate → มีประสิทธิภาพสูงกว่าโมเดลก่อนหน้านี้ เช่น UNet



BiomedParse (2025)

- ใช้ SAM + PubMedBERT เช่นกัน
- สามารถทำ Segmentation, Object detection, และ Object recognition ได้ เช่นเดียวกับ SAM
- เทรนด้วย **4 ล้านเซตข้อมูล** ที่แต่ละเซตประกอบด้วย image-mask-label ซึ่งครอบคลุม **9 modalities** และ 25 โครงสร้างของร่างกาย
- เคลมว่าทำงานได้ดีกว่า MedSAM
- แต่สามารถ Segment ได้ดีเฉพาะ Target ที่เคยใช้ใน Pre-training



Models Comparison between end-to-end object recognition (รวมถึง segmentation)

Data Data Data: NLP

BERT (2018) → SciBERT (2019), BioBERT (2019), PubMedBERT (2020)

- เทรนด์การพัฒนาของการประมวลผลภาษาทางด้านการแพทย์ก็ follow คล้ายกับโมเดลด้าน Computer Vision
- PubMedBERT ใช้ Corpus ต่างจาก BERT (Wiki + Books), Roberta (Web crawl) คือใช้ PubMed – PMC full text 3.1B words เทียบเท่า Wikipedia
- สร้าง Tokenizers / Pretrain ใหม่ให้เหมาะกับข้อมูลทางวิทยาศาสตร์ ศัพท์แพทย์มากกว่า
- ความสามารถของ BERT นำมาใช้ดึงข้อมูลที่สำคัญ เช่น ผลคำวินิจฉัย หรือ แผนการรักษา






Fig. 1. Two paradigms for neural language model pretraining. Top: The prevailing mixed-domain paradigm assumes that out-domain text is still helpful and typically initializes domain-specific pretraining with a general-domain language model and inherits its vocabulary. Bottom: Domain-specific pretraining from scratch derives the vocabulary and conducts pretraining using solely in-domain text. In this paper, we show that for domains with abundant text such as biomedicine, domain-specific pretraining from scratch can substantially outperform the conventional mixed-domain approach.

From large pretrained model to LLM

- LLM ยุคปัจจุบันเทรนและ instruction fine-tune ด้วยข้อมูลขนาดใหญ่ (trillion tokens)
- ความสามารถของ LLM นำมาใช้ในการวิเคราะห์ข้อมูล medical reports เพื่อดึงข้อมูลที่สำคัญ เช่น สร้างผลคำวินิจฉัย, แผนการรักษา, summarization, ตอบคำถามการแพทย์
- ในปี 2023 โมเดล LLM เช่น MedPaLM2 เทรนด้วย PaLM 2 เริ่มชนะใน task การตอบคำถามทางการแพทย์ MedQA
- Dataset QA ถูกพัฒนาขึ้นมา เช่น MedQuAD (คล้าย SQuAD) มี 47k ข้อ และ MedQA มี 61k ข้อ



MedQA with LLM


- หลังจากที่ ChatGPT เปิดตัวในปี 2022 → นักวิจัยเริ่มนำ LLM และ Multimodal LLM มาใช้ทางการแพทย์มากขึ้นกว่าเดิม
- ใช้ LLM เช่น Med-Gemini/GPT-4 ปัจจุบันคะแนนกระโดดจาก BioBERT ~40% ไปถึงเกือบ 95% ด้วย
- ข้อเสียคือไม่มีการเปิดเผยข้อมูลของการเทรนโมเดลเหล่านี้เท่าไร, มีการใช้ proprietary data จำนวนมาก

Question	A 27-year-old male presents to urgent care complaining of pain with urination. He reports that the pain started 3 days ago. He has never experienced these symptoms before. He <i>denies gross hematuria or pelvic pain</i> . He is sexually active with his girlfriend, and they consistently use condoms. When asked about recent travel, he admits to recently returning from a boys' trip in Cancun where he had <i>unprotected sex</i> 1 night with a girl he met at a bar. The patients medical history includes type 1 diabetes that is controlled with an insulin pump. His mother has rheumatoid arthritis. The patients temperature is 99 F (37.2 C), blood pressure is 112/74 mmHg, and pulse is 81/min. On physical examination, there are no lesions of the penis or other body rashes. No costovertebral tenderness is appreciated. A urinalysis reveals no blood, glucose, ketones, or proteins but is <i>positive for leukocyte esterase</i> . A urine microscopic evaluation shows a <i>moderate number of white blood cells</i> but no casts or crystals. A urine culture is negative. Which of the following is the most likely cause for the patient's symptoms?
Options	A: Chlamydia trachomatis , B: Systemic lupus erythematosus, C: Mycobacterium tuberculosis, D: Treponema pallidum
Evidence	At least one-third of male patients with <i>C. trachomatis</i> urethral infection have <i>no evident signs or symptoms of urethritis</i> Such patients generally have <i>pyuria</i> ..., a <i>positive leukocyte esterase test</i> , ...
Question	A 57-year-old man presents to his primary care physician with a 2-month history of <i>right upper and lower extremity weakness</i> . He noticed the weakness when he started falling far more frequently while running errands. Since then, he has had <i>increasing difficulty</i> with walking and lifting objects. His past medical history is significant only for well-controlled hypertension, but he says that some members of his <i>family have had musculoskeletal problems</i> . His right upper extremity shows <i>forearm atrophy</i> and <i>depressed reflexes</i> while his right lower extremity is <i>hypertonic with a positive Babinski sign</i> . Which of the following is most likely associated with the cause of this patients symptoms?
Options	A: HLA-B8 haplotype, B: HLA-DR2 haplotype, C: Mutation in SOD1 , D: Mutation in SMN1, E: Viral infection
Evidence	1. The manifestations of ALS ..., <i>insidiously developing asymmetric weakness</i> , usually first evident distally in one of the limbs. 2. ... <i>hyperactivity of the muscle-stretch reflexes (tendon jerks)</i> and, often, <i>spastic resistance to passive movements</i> ... 3. <i>Familial ALS (FALS)</i> ... clinically indistinguishable from sporadic ALS... Genetic studies have identified mutations in multiple genes, including cytosolic enzyme <i>SOD1</i> ...

Table 1: Two examples of MEDQA. The correct answer among options is marked in bold font. Key words in the question and evidence text to help answer the questions are highlighted in italic font. Evidence for both examples are from the textbook “Harrison’s Principles of Internal Medicine”.

ตัวอย่างของข้อสอบ MedQA → อ่านบริบท และตอบแบบ multiple choices

Question Answering on MedQA



ArchEHR-QA, BioNLP@ACL 2025

- การนำ LLM มาใช้ในงานที่เฉพาะทางขึ้นมา
- LLM สามารถนำมาใช้ในการตอบคำถาม ในกรณีมี grounded information เช่น มีคำถามจากคนไข้, Clinical note → ต้องการคำตอบที่ใช้ Clinical note มาเป็น reference ในการตอบ

Example #1

Patient Question (*underlined is the main question*)

Took my 59 yo father to ER ultrasound discovered he had an aortic aneurysm. He had a salvage repair (tube graft). Long surgery / recovery for couple hours then removed packs. why did they do this surgery???? After this time he spent 1 month in hospital now sent home.

Clinician Question

Why did they perform the emergency salvage repair on him?

Clinical Note (*sentences numbered for grounding*)

1: He was transferred to the hospital on 2025-1-20 for emergent repair of his ruptured thoracoabdominal aortic aneurysm. **2:** He was immediately taken to the operating room where he underwent an emergent salvage repair of ruptured thoracoabdominal aortic

Answer (*hover over a citation to highlight relevant sentences*)

His aortic aneurysm was caused by the rupture of a thoracoabdominal aortic aneurysm, which required emergent surgical intervention (1). He underwent a complex salvage repair using a 34-mm Dacron tube graft and deep hypothermic circulatory arrest to address the rupture (2). The extended recovery time and hospital stay were necessary due to the severity of the rupture and the complexity of the surgery, though his wound is now healing well with only a small open area noted (8).

Example of clinical questions

ArchEHR-QA, BioNLP@ACL 2025

- นำ LLM มาสร้างคำถามจาก electronic medical records จากนั้นใช้เป็น few-shot exemplars (in-context learning)
- พบว่าการเรียนรู้ผ่าน few-shot prompting ทำให้สามารถตอบคำถามได้ดีกว่าการ zero-shot prompting เดิม

Approach	Model	Overall	Factual.	Relev.
Baseline	GPT-4.1	47.9	53.8	42.1
	Gemini-2.0-Flash	45.0	49.2	40.8
	Claude-3.7-Sonnet	48.1	57.1	39.2
Few-shot: basic	GPT-4.1	48.6	57.8	39.4
	Gemini-2.0-Flash	47.5	56.3	38.8
	Claude-3.7-Sonnet	48.1	55.6	40.6
Few-shot: LLM-generated exemplars	GPT-4.1	51.5	61.1	41.8
	Gemini-2.0-Flash	50.5	59.6	41.5
	Claude-3.7-Sonnet	49.6	58.4	40.7
Few-shot: exemplars with reasoning	GPT-4.1	47.3	55.6	39.0
	Gemini-2.0-Flash	51.0	58.1	43.9
	Claude-3.7-Sonnet	49.3	55.5	43.1
RAG: articles	GPT-4.1	46.4	53.3	39.5
	Gemini-2.0-Flash	45.7	50.0	41.5
	Claude-3.7-Sonnet	47.4	55.3	39.5
RAG: article summaries	GPT-4.1	46.7	52.8	40.5
	Gemini-2.0-Flash	45.7	49.0	42.3
	Claude-3.7-Sonnet	46.9	54.7	39.1
RAG: synthetic cases	GPT-4.1	47.1	56.3	37.9
	Gemini-2.0-Flash	48.9	58.2	39.7
	Claude-3.7-Sonnet	47.8	55.3	40.3

Submission	Overall	Factual.	Relev.
Exemplars as few-shot with Gemini-2.0-Flash	48.5	54.6	42.5
Exemplars as few-shot with GPT-4.1	48.6	57.3	39.8
Multistage few-shot prompting (Figure 1)	49.1	56.9	41.4




Figure 1: The multistage few-shot prompting pipeline of our system submitted to ArchEHR-QA 2025.

EC-RAFT @ACL 2025

- การพัฒนาการสร้าง eligibility criteria (EC) ที่ใช้ clinical trials ด้วยข้อมูลจาก ClinicalTrials.gov มา fine-tune ผ่านเทคนิค Retrieval Augmented Fine-Tuning (RAFT) ผ่าน LLMs เช่น Llama3.1-8B พร้อมนำ LLMs มาใช้ในการประเมินผลอีกด้วย
- ใช้ 1) Retrieval ในการใช้ relevant information, 2) Reasoning ในการให้ LLM คิดก่อนตอบ → Fine-tune LLM (Llama 3.1)





Figure 1: **Overview of the EC-RAFT pipeline.** **A.** (1) Data embedding using SciNCL (2) Retrieve relevant trials and their ECs (D) for the trial of interest (X), then combine with desired ECs (y) to generate intermediate steps (R). **B.** Fine-tune the model to generate a single response that includes both reasoning and final eligibility. **C.** Evaluate using two approaches: (1) **BERTScore** (Zhang et al., 2020) for semantic similarity, and (2) **LLM-Guided Evaluation** for clinical relevance of matched EC pairs.

EC-RAFT @ACL 2025

- นอกจากนั้นในงานก่อนหน้าไม่ค่อยมีงานไหนใช้ LLM-guided evaluation ซึ่งเป็นสิ่งที่ขาดใน EC prediction
→ BERT Score อย่างเดียวไม่สามารถเก็บรายละเอียดของ textual information ที่ใกล้เคียงกันได้
- การทำนายอาจสลับ inclusion / exclusion ออกจากกัน เช่น อายุเกิน 18 ปี (inclusion) vs. อายุ~~ไม่~~เกิน 18 ปี (exclusion)
- ทดสอบการให้คะแนนเทียบกับแพทย์แล้วได้ Interater ~ 89.2% (high), correlation ~ 90.26% (high)



- Clinical relevance 3 → Clinically identical EC.
- Clinical relevance 2 → Strongly relevant due to factors like disease progression or epidemiology.
- Clinical relevance 1 → Loosely relevant due to general treatment plans, disease progression, or epidemiological factors.
- Clinical relevance 0 → Irrelevant from a clinical perspective.

EC-RAFT

เมื่อเทียบผลพบว่าในภาพรวม EC-RAFT สามารถสร้างและอ้างอิง EC ได้ใกล้เคียงกับ EC มากที่สุด, Gemini-1.5 flash มี Recall ที่มากกว่าเล็กน้อย แต่ก็มาพร้อมกับ Precision ที่ต่ำกว่า แสดงถึงความสามารถของการสร้าง EC ที่มากแต่อาจจะมากเกินไปจนความจำเป็น

นอกจากนี้ยังพบว่าเมื่อใช้ LLM ที่โมเดลใหญ่กว่าใน Intermediate reasoning steps ก็จะเพิ่มประสิทธิภาพในการสร้าง EC ให้มากขึ้น

Model	BERTScore $\uparrow$	LLM-guided Evaluations			
		Precision $\uparrow$	Recall $\uparrow$	Mean Judge Score $\uparrow$	Mean Pair-BERTScore $\uparrow$
LLaMA 3.1-8B-Instruct (Zero-shot)	81.42	77.16	67.63	1.3097	51.95
LLaMA 3.1-8B-Instruct (Fine-tuned)	83.01	61.42	70.16	1.5114	61.49
Meditron-7b (Biomedical DSF + Fine-tuned)	82.96	60.72	71.23	1.5748	62.59
Gemini-1.5-flash-002 (Zero-shot)	82.18	72.47	78.34	1.6004	63.66
EC-RAFT (R from LLaMA 3.1-8B)	86.35	72.55	61.20	1.5932	66.92
EC-RAFT (R from Gemini-1.5-flash)	86.23	78.84	75.89	1.7150	67.76

Table 2: Comparison of zero-shot and fine-tuned baselines alongside EC-RAFT.

Multimodal LLM

- นำ Adapter มาต่อกับ LLM ทำให้ LLM สามารถรับข้อมูล ภาพ/เสียง ได้
- **HeLM**: Health Large Language Model for Multimodal Understanding เทรน LLM ด้วยข้อมูลของ UK Biobank นำข้อมูล demographic และ time series data ใส่ให้กับ LLM
- **MedGemma 4B, 27B** ซึ่งเป็น pre-training เริ่มต้น นำไปใช้ในการทำ medical images classification ในภาพเช่น radiology, digital pathology, fundus และ skin images





Fig. 1: Overview of HeLM, a multimodal LLM for health. Text features (orange) are tokenized and embedded into the token embedding space via a standard embedding matrix. Non-text modalities such as clinical data (blue) or high-dimensional lung function measures (green) are encoded into the same token embedding space via modality-specific encoders. The LLM is tuned to quantify disease risk given complex multimodal inputs.

LISA (2024)

- โจทย์คือ text + ภาพ → ดึง binary segmentation จากภาพ
- แต่ปรับโจทย์ของ Text ให้ยากขึ้น โดยการเปลี่ยนจาก Textual information ปกติ เช่น หาถึงขยะให้หน่อย เป็นอะไรก็ได้ที่เอาไวใส่ขยะ
- ใช้ VisionLLM เป็น base และ fine-tune ด้วยข้อมูลที่เตรียมเพิ่ม เช่น COCO-Stuff, ADE20K, PACO-LVIS, refCOCO, ...




Figure 3. The pipeline of LISA. Given the input image and text query, the multimodal LLM (e.g., LLaVA [29]) generates text output. The last-layer embedding for the <SEG> token is then decoded into the segmentation mask via the decoder. We use LoRA [15] for efficient fine-tuning. The choice of vision backbone can be flexible (e.g., SAM [66], Mask2Former [9]).





Figure 1. We unlock new segmentation capabilities for existing multimodal LLMs. Our model (i.e., LISA) can deal with cases involving complex reasoning and world knowledge. Also, we demonstrate the cases of explanatory answers in the 3rd row. Additionally, in the 4th row, our model can output multiple segmentation masks in a single answer. More illustrations can be found in the supplementary material.

LLM-Seg (2024)

- ปรับ Architecture จาก LISA ที่ใช้ <SEG> token ใน Reasoning Segmentation โดยเพิ่ม Mask pooling step
- LLM-Seg ใช้ SAM, DINOv2, LLaVa-7B และ Mask selection module
- สามารถ Segment ออกมาได้ดีกว่า LISA ในภาพรวม แต่ก็มีโอกาส Segment เกินมากกว่า



Method	Use LLM	Zero-Shot	gIoU	cIoU	ncIoU
GRES [21]	×	✓	22.4	19.9	-
OVSeg [19]	×	✓	28.5	18.6	-
X-Decoder [39]	×	✓	22.6	17.9	-
SEEM [40]	×	✓	22.5	21.2	-
LISA [16]	✓	×	51.0	50.6	48.1
LISA (20 epochs)	✓	✓	44.4	46.0	-
LISA (20 epochs)	✓	×	52.9	54.0	-
LLaVA+GroundingSAM	✓	✓	47.4	34.6	34.4
LLM-Seg	✓	✓	47.4	35.4	43.5
LLM-Seg	✓	×	52.3	47.5	<u>48.8</u>
LLM-Seg (20 epochs)	✓	×	55.4	45.6	51.0



“LLM-Seg: Bridging Image Segmentation and Large Language Model Reasoning,” *Arxiv.org*, 2022. Available: <https://arxiv.org/html/2404.08767v1>. [Accessed: Jun. 02, 2025]

EVF-SAM (2025)

- ใช้ Early-fusion mechanism คือใช้ Shallow-embedding layers และ Deep fusion layers เพื่อพัฒนาขั้นตอนการทำ image-to-text attention และ text-to-image attention
- นอกจากจะลดเวลาในการ Train และ Evaluate แล้ว ยังพบว่า EVF-SAM สามารถ Segment ได้ดีกว่าทั้ง SAM with text encoder เช่น LAVT และ SAM with LLM เช่น LISA




Figure 5. **The overall architecture of EVF-SAM.** The proposed EVF-SAM maintains the original architecture of SAM and keeps the weights of the SAM Image Encoder frozen. EVF-SAM exploits the Multimodal Encoder with Early Vision-Language Fusion (EVF) to encode both text prompts and the low-resolution input image (which is resized to 224×224). Then the output $[CLS]$ token is projected as prompt embeddings and fed into the prompt encoder of SAM for generating the referring segmentation results.

Method	Text Prompt Encoder	SAM?	Training Data	RefCOCO			RefCOCO+			RefCOCOg		AVG
				val	testA	testB	val	testA	testB	val	test	
LAVT [69]	BERT-B (104M)	✗	RC, gRC	72.7	75.8	68.8	62.1	68.4	55.1	-	-	-
PolyFormer-L [38]	BERT-B (104M)	✗	RC, gRC	76.9	78.5	74.8	72.2	75.7	66.7	71.2	71.2	73.4
UNINEXT-H [67]	BERT-B (104M)	✗	O, C, RC, V	82.2	83.4	81.3	72.5	76.4	66.2	74.4	76.4	76.6
UniLSeg-100 [39]	CLIP-B (63M)	✗	SA, RC, gRC	81.7	83.2	79.9	73.2	78.3	68.2	-	-	-
UniRef++-L [61]	BERT-B (104M)	✗	RC, F, V	79.1	82.1	77.5	68.4	74.0	61.5	71.4	72.8	73.4
LISA [25]	Vicuna (7B)	✓	A, CS, RC, PL, PP	74.1	76.5	71.1	62.4	67.4	56.5	66.4	68.5	67.9
PixelLM [30]	LLaMA2 (13B)	✗	A, CS, RC, PL, M	73.0	76.5	68.2	66.3	71.7	58.3	69.3	70.5	69.2
PixelLLM [66]	T5-XL (3B)	✓	RC, GG	76.9	78.5	74.4	69.2	72.1	64.5	70.7	72.4	72.3
GLaMM [47]	Vicuna (7B)	✓	G, RC	79.5	83.2	76.9	72.6	78.7	64.6	74.2	74.9	75.6
u-LLaVA [68]	Vicuna (7B)	✓	A, CS, RC, PL, PV	80.4	82.7	77.8	72.2	76.6	66.8	74.8	75.6	75.9
PSALM [75]	Phi-1.5 (1.3B)	✗	C, RC, CI	83.6	84.7	81.6	72.9	75.5	<u>70.1</u>	73.8	74.4	77.1
EVF-SAM	BEIT-3 (673M)	✓	RC	82.1	83.7	80.0	<u>75.2</u>	78.3	<u>70.1</u>	<u>76.8</u>	<u>77.4</u>	<u>78.0</u>
EVF-SAM	BEIT-3 (673M)	✓	RC, O, A, PP, PIN, HP	<u>82.4</u>	<u>84.2</u>	80.2	76.5	80.0	71.9	78.2	78.3	79.0

Radiology Report Generation, RRG @BioNLP ACL (2024)

- ตัวอย่าง BioNLP solution อันดับ 5 ที่ใช้ในการสร้าง report จากภาพ X-ray
- ใช้โมเดล เช่น CLIP Encoder ในการสรุปภาพ X-ray
- จากนั้นต่อกับ LLM เช่น Vicuna 7b เพื่อ generate findings (สิ่งที่เจอจากภาพ), impressions (สรุปของ radiologist จากสิ่งที่เจอจากภาพอีกที)
- ปัจจุบัน encoder / decoder (LLM) มีประสิทธิภาพมากกว่าเดิม


FINDINGS

There has been an increase in size of the left pleural effusion compared to the prior exam. The right lung remains clear with no evidence of consolidation or pneumothorax. The heart size is mildly enlarged but stable. The mediastinum appears unremarkable. Mild degenerative changes are noted in the thoracic spine and ribs. The upper abdomen is without remarkable findings.

IMPRESSIONS

Increase in left pleural effusion compared to prior. Stable mild cardiomegaly. No evidence of right lung pathology.

Table 1: FINDINGS and IMPRESSIONS in a synthetic radiology report generated by GPT-4.



SegVol (2023)

- เทรนด้วย 90,000 unlabeled CT volumes และ 6,000 labeled CT volumes ทำให้สามารถ segment แบบ 3D ได้ มากกว่า 200 โครงสร้างของร่างกาย ซึ่งสามารถ Segment ได้ดีกว่าโมเดลอย่าง SAM-MED3D กว่า 37.24% ในบาง Task
- ใช้ 3D ViT และ CLIP รวมทั้งพัฒนา Zoom-out-zoom-in Mechanism เพื่อให้ Region of Interest ได้ดียิ่งขึ้น
- แต่ยังมีข้อจำกัดในการใช้ Prompt ที่ยาวมากขึ้นและมีความหลากหลายมาก




Table 2: Quantitative comparative experiment results for SegVol and other 5 SAM-like interactive segmentation methods settings in terms of the median value of Dice score.

Dataset	Category	SAM(Point) [28]	SAM(Bbox) [28]	SAM-MED2D [38]	SAM-MED3D [39]	MedSAM [29]	OURS
AMOS22 [44]	Aorta	0.7267	0.4362	0.8704	0.8102	0.3387	0.9273
	Bladder	0.4162	0.6281	0.8417	0.4338	0.6799	0.9120
	Duodenum	0.1554	0.3192	0.5066	0.3820	0.3066	0.7402
	Esophagus	0.2917	0.3541	0.5500	0.5174	0.3610	0.7460
	Gallbladder	0.2831	0.6161	0.7999	0.5643	0.6609	0.8763
	Adrenal gland(L)	0.0555	0.4222	0.5068	0.4584	0.3766	0.7295
	Left kidney	0.8405	0.8274	0.9325	0.8723	0.7909	0.9489
	Liver	0.7477	0.5124	0.6904	0.8801	0.6137	0.9641
	Pancreas	0.2127	0.3392	0.5656	0.5391	0.3217	0.8295
	Postcava	0.2042	0.5251	0.4436	0.6683	0.5211	0.8384
	Prostate uterus	0.2344	0.6986	0.7518	0.6231	0.7739	0.8557
	Adrenal gland(R)	0.0452	0.3642	0.1681	0.3708	0.3855	0.6994
	Right kidney	0.8459	0.8215	0.9077	0.8632	0.7851	0.9505
	Spleen	0.5936	0.6536	0.9267	0.8591	0.7038	0.9589
	Stomach	0.4229	0.3883	0.5399	0.4576	0.4378	0.9123
	Average	0.4050	0.5271	0.6668	0.6200	0.5371	0.8593
ULS23 [74]	DeepLesion3D	0.3686	0.7473	0.3258	0.2386	0.7065	0.7680
	BoneLesion	0.4461	0.6671	0.1947	0.4447	0.6896	0.6920
	PancreasLesion	0.0675	0.5579	0.5548	0.5526	0.6561	0.7265
	Average	0.2941	0.6574	0.3584	0.4120	0.7046	0.7046
SegTHOR [75]	Aorta	0.2744	0.3894	0.8077	0.7703	0.3278	0.8439
	Esophagus	0.0348	0.2046	0.3578	0.6394	0.2196	0.7201
	Heart	0.6695	0.8876	0.6012	0.8325	0.8924	0.8172
	Trachea	0.9147	0.1611	0.8306	0.8485	0.1261	0.8807
	Average	0.4734	0.4107	0.6493	0.7727	0.3915	0.8155

Y. Du, F. Bai, T. Huang, and B. Zhao, "SegVol: Universal and Interactive Volumetric Medical Image Segmentation," arXiv.org, 2023. Available: <https://arxiv.org/abs/2311.13385>. [Accessed: Jun. 02, 2025]

What's next?

- Deep learning เริ่มเข้ามามีบทบาทใน Medical Image Analysis
 - [2013 - now] Pre-trained Convolution Neural Network (CNN)
→ ใช้ใน **tasks หลักๆ** เช่น Image classification, Semantic Segmentation, Object detection, Image reconstruction, Deep learning ชะงักเกือบทุก tasks ข้างต้นและกลายเป็นโมเดลที่ใช้แพร่หลาย
 - [2017 - now] **Transformers** → หลังจากที่ข้อมูลเริ่มมีการ scale มากขึ้น Transformers ทำงานได้ดีมากขึ้นและถูกนำมาใช้มากขึ้น

เทรนดีเทรนโมเดลด้วย data ที่มากขึ้น

- [2020 - now] Early Multimodal Model → เริ่มนำ modalities มารวมกัน เช่น CLIP
- [2022 - now] Large Language Model (LLM) → เริ่ม**ตอบคำถามทางด้านการแพทย์**ได้ดี
- [2023 - now] Multimodal LLM → ยุคปัจจุบันที่**นำ modality ต่างๆมารวมกับ LLM**

