


การรู้จำการกระทำจากวิดีโอ (Video Action Recognition) ในยุค AI สมัยใหม่: ทฤษฎี เทคนิค และการประยุกต์ใช้งาน

ดร.วัชระ เรืองสังข์ | 17 มิถุนายน 2568



Outline

- พื้นฐาน Action Recognition
 - แนวคิดและความสำคัญของ Action Recognition
 - วิวัฒนาการและสถาปัตยกรรมหลัก
 - ชุดข้อมูลและการประเมินผล
- แนวโน้มวิจัยปัจจุบัน
 - Fine-grained Action Recognition
 - Multi-modal Learning
 - Zero-shot & Few-shot Learning
- การประยุกต์ใช้และแนวโน้มอนาคต
 - การเลือกวิธีการให้เหมาะกับโจทย์
 - ทิศทางการวิจัยในอนาคต

พื้นฐานของ Action Recognition

- การรู้จำท่าทาง (Action Recognition) คือ สาขาหนึ่งของปัญญาประดิษฐ์ (AI: Artificial Intelligence) และคอมพิวเตอร์วิทัศน์ (Computer Vision) ที่มีเป้าหมายเพื่อให้เครื่องคอมพิวเตอร์สามารถเข้าใจและระบุ "กิจกรรม" หรือ "ท่าทาง" ที่เกิดขึ้นในวิดีโอได้
- เป้าหมาย: ไม่ใช่แค่การตรวจจับวัตถุ (Object Detection) แต่เป็นการทำความเข้าใจ "สิ่งที่วัตถุกำลังทำ" ในช่วงเวลาหนึ่ง
- ตัวอย่าง: "คนกำลังเดิน", "รถกำลังเลี้ยวซ้าย", "นักกีฬา กำลังชู้ตบาส"



Action Recognition on Kinetics-400 (left) and Skeleton-based Action Recognition on NTU-RGB+D-120 (right)




Skeleton-based Spatio-Temporal Action Detection and Action Recognition Results on Kinetics-400



Spatio-Temporal Action Detection Results on AVA-2.1

ความสำคัญและแอปพลิเคชัน (Importance & Applications)

1. การรักษาความปลอดภัยอัจฉริยะ (Intelligent Surveillance) ตรวจสอบพฤติกรรมที่น่าสงสัย เช่น การทิ้งวัตถุ, การทะเลาะวิวาท
2. การวิเคราะห์ทางการกีฬา (Sports Analytics) วิเคราะห์ฟอร์มการเล่นของนักกีฬา, สรุปไฮไลท์การแข่งขันอัตโนมัติ
3. การดูแลสุขภาพ (Healthcare): ติดตามการทำกายภาพบำบัดของผู้ป่วย, ตรวจสอบการหกล้มของผู้สูงอายุ
4. การวิเคราะห์พฤติกรรมมนุษย์ (Human Behavior Analysis): การวิเคราะห์ภาษากายในการสัมภาษณ์, การประเมินการมีส่วนร่วมในการประชุม




วิวัฒนาการของ Action Recognition

- ยุคก่อนการเรียนรู้เชิงลึก (Pre-Deep Learning Era):
 - ใช้ คุณลักษณะที่สร้างขึ้นด้วยมือ (Hand-crafted Features)
 - เช่น HOG (Histogram of Oriented Gradients) สำหรับรูปร่าง, HOF (Histogram of Optical Flow) สำหรับการเคลื่อนไหว
 - ข้อจำกัด: ผลไม่ดีเมื่อมีปัจจัย ความหลากหลายของมุมมอง, สภาพแสง และฉากหลัง
- ยุคการเรียนรู้เชิงลึก (Deep Learning Era):
 - โมเดลเรียนรู้คุณลักษณะ (Features) จากข้อมูลโดยตรง
 - มีความแม่นยำและทนทานสูงมาก


คุณลักษณะเชิงพื้นที่-เวลา (Core Concept: Spatio-temporal Features)

- วิดีโอคือลำดับของรูปภาพ (Frames)
- การจะเข้าใจ "ท่าทาง" ได้นั้น ต้องอาศัยข้อมูล 2 มิติพร้อมกัน
 - 1. คุณลักษณะเชิงพื้นที่ (Spatial Features): “ในภาพมีอะไร?”
 - คือข้อมูลจาก เฟรมเดียว เช่น รูปร่างของคน, วัตถุที่เกี่ยวข้อง
 - สกัดได้ด้วยโครงข่ายประสาทแบบสังวัตนาการ (CNN: Convolutional Neural Network)
 - 2. คุณลักษณะเชิงเวลา (Temporal Features): “สิ่งนั้นเปลี่ยนแปลงไปอย่างไรตามเวลา?”
 - คือข้อมูล ระหว่างเฟรม เช่น ทิศทางการเคลื่อนที่ของแขน, ความเร็วในการเดิน



การสกัดคุณลักษณะสำคัญสำหรับพฤติกรรมมนุษย์

- การวิเคราะห์พฤติกรรมมนุษย์ มีคุณลักษณะ 2 อย่างที่สำคัญอย่าง
- การประมาณค่าโครงสร้างร่างกาย (Pose Estimation): คือการหาตำแหน่งข้อต่อสำคัญของร่างกาย (Keypoints) เพื่อวิเคราะห์ "ภาษากาย" (Body Language) เช่น ท่าทาง, การกอดอก, การเอนตัว ซึ่งเป็นข้อมูลโดยตรงที่สื่อถึงสภาวะภายใน
- การตรวจจับจุดสำคัญบนใบหน้า (Facial Landmark Detection): คือการหาตำแหน่งจุดต่างๆ บนใบหน้า เพื่อวิเคราะห์ "การแสดงออกทางสีหน้าที่ละเอียดอ่อน" (Micro-expressions) และทิศทางการมอง (Gaze) ซึ่งเชื่อมโยงกับความมั่นใจ, ความสนใจ, และอารมณ์




https://ai.google.dev/edge/mediapipe/solutions/vision/pose_landmarker



https://ai.google.dev/edge/mediapipe/solutions/vision/face_landmarker

สถาปัตยกรรมยุคบุกเบิก (Classic Architectures) - 2D CNN + RNN

- **แนวคิด:** แยกการประมวลผล Spatial และ Temporal ออกจากกัน
- **ขั้นตอน:**
 - ใช้ 2D CNN (ที่ฝึกสอนล่วงหน้าบน ImageNet) เพื่อสกัด "คุณลักษณะเชิงพื้นที่" จากแต่ละเฟรมของวิดีโอ ได้เป็น เวกเตอร์ของคุณลักษณะ (Feature Vector) ต่อเฟรม
 - นำลำดับของเวกเตอร์เหล่านี้ป้อนเข้า RNN (Recurrent Neural Network) หรือ LSTM (Long Short-Term Memory) เพื่อเรียนรู้ "ความสัมพันธ์เชิงเวลา"
- **ข้อดี:** เรียบง่าย, ใช้ประโยชน์จากโมเดลรูปภาพที่มีอยู่แล้วได้
- **ข้อเสีย:** อาจสูญเสียข้อมูลการเคลื่อนไหวระยะสั้น ระหว่างเฟรมไปในขั้นตอนแรก



Long-term Recurrent Convolutional Networks (LRCNs)

การทำงานของ LSTM ในบริบทวิดีโอ

- โครงสร้าง LSTM สำหรับวิดีโอ:
 - Input Gate: ควบคุมข้อมูลใหม่จากเฟรมปัจจุบัน
 - Forget Gate: ตัดสินใจว่าจะลืมข้อมูลเก่าหรือไม่
 - Output Gate: กำหนดข้อมูลที่จะส่งต่อ
 - Cell State: เก็บข้อมูลระยะยาวของการเคลื่อนไหว
- ข้อดีสำหรับ Action Recognition:
 - จัดการกับวิดีโอที่มีความยาวต่างกันได้
 - เรียนรู้ความสัมพันธ์ระยะยาวของการเคลื่อนไหว




Figure 3: Each LSTM cell remembers a single floating point value c_t (Eq. 5). This value may be diminished or erased through a multiplicative interaction with the forget gate f_t (Eq. 4) or additively modified by the current input x_t multiplied by the activation of the input gate i_t (Eq. 3). The output gate o_t controls the emission of h_t , the stored memory c_t transformed by the hyperbolic tangent nonlinearity (Eq. 6,7). Image duplicated with permission from Alex Graves.

การประยุกต์ใช้ Two-Stream Architecture

- แนวคิด Two-Stream:
 - Spatial Stream: เรียนรู้จากเฟรม RGB
 - Temporal Stream: เรียนรู้จาก Optical Flow
 - การรวมผลลัพธ์: Late Fusion vs Early Fusion




Figure 1: Two-stream architecture for video classification.

- การพัฒนาต่อยอด:
 - TSN (Temporal Segment Networks)
 - TRN (Temporal Relation Networks)
 - การใช้ Attention Mechanism






Figure 2: **Optical flow.** (a),(b): a pair of consecutive video frames with the area around a moving hand outlined with a cyan rectangle. (c): a close-up of dense optical flow in the outlined area; (d): horizontal component d^x of the displacement vector field (higher intensity corresponds to positive values, lower intensity to negative values). (e): vertical component d^y . Note how (d) and (e) highlight the moving hand and bow. The input to a ConvNet contains multiple flows (Sect. 3.1).

สถาปัตยกรรมยุคบุกเบิก (Classic Architectures) - 3D CNN


- **แนวคิด:** เรียนรู้คุณลักษณะเชิงพื้นที่และเวลาไปพร้อมๆ กัน
- **วิธีการ:** แทนที่จะใช้ฟิลเตอร์ (Filter) แบบ 2 มิติ (กว้าง x สูง) เหมือน CNN ทั่วไป, 3D CNN จะใช้ฟิลเตอร์แบบ 3 มิติ (กว้าง x สูง x เวลา)
- ทำให้ฟิลเตอร์สามารถ "มองเห็น" การเปลี่ยนแปลงเล็กๆ น้อยๆ ข้ามหลายเฟรมได้ในคราวเดียว
- **สถาปัตยกรรมเด่น :** C3D (Convolutional 3D), I3D (Inflated 3D)
- **ข้อดี:** จับการเคลื่อนไหวระยะสั้นได้ดีมาก
- **ข้อเสีย:** ใช้การคำนวณและหน่วยความจำสูงมาก



(a) 2D convolution



(b) 2D convolution on multiple frames



(c) 3D convolution

จาก C3D สู่ I3D

- วิวัฒนาการของ 3D CNN:
 - C3D (2015): 3D Convolution พื้นฐาน
 - P3D (2017): แยก 3D เป็น 2D + 1D
 - I3D (2017): Inflate จาก 2D Pre-trained
 - R(2+1)D (2018): Factorized convolutions
- การเพิ่มประสิทธิภาพ:
 - ลดจำนวน Parameters
 - ใช้ประโยชน์จาก ImageNet Pre-training
 - เพิ่ม Temporal Modeling Capacity




Figure 2. **(2+1)D vs 3D convolution.** The illustration is given for the simplified setting where the input consists of a spatiotemporal volume with a single feature channel. (a) Full 3D convolution is carried out using a filter of size $t \times d \times d$ where t denotes the temporal extent and d is the spatial width and height. (b) A (2+1)D convolutional block splits the computation into a spatial 2D convolution followed by a temporal 1D convolution. We choose the numbers of 2D filters (M_i) so that the number of parameters in our (2+1)D block matches that of the full 3D convolutional block.




Figure 3. **Training and testing errors for R(2+1)D and R3D.** Results are reported for ResNets of 18 layers (left) and 34 layers (right). It can be observed that the training error (thin lines) is smaller for R(2+1)D compared to R3D, particularly for the network with larger depth (right). This suggests that the the spatial-temporal decomposition implemented by R(2+1)D eases the optimization, especially as depth is increased.

สถาปัตยกรรม Vision Transformer (ViT)

- Transformer เดิมที่ถูกสร้างเพื่องานประมวลผลภาษาธรรมชาติ (NLP: Natural Language Processing)
- Vision Transformer (ViT) คือการนำแนวคิด Transformer มาประยุกต์ใช้กับรูปภาพและวิดีโอ
- วิธีการสำหรับวิดีโอ:
 - แบ่งวิดีโอออกเป็น "ก้อน" (Tubelets) หรือส่วน (Patches) ในหลายๆ เฟรม
 - แปลงแต่ละก้อนให้เป็น Token
 - ใช้กลไก **Attention** เพื่อหาความสัมพันธ์ระหว่างก้อนต่างๆ ทั้งทั้งวิดีโอ
- ข้อดี: สามารถจับ "ความสัมพันธ์ระยะไกล" (Long-range dependencies) ได้ดีเยี่ยม เหมาะกับการวิเคราะห์กิจกรรมที่ยาวนานและซับซ้อน




Figure 1: We propose a pure-transformer architecture for video classification, inspired by the recent success of such models for images [17]. To effectively process a large number of spatio-temporal tokens, we develop several model variants which factorise different components of the transformer encoder over the spatial- and temporal-dimensions. As shown on the right, these factorisations correspond to different attention patterns over space and time.




Figure 2: Uniform frame sampling: We simply sample n_t frames, and embed each 2D frame independently following ViT [17].




Figure 3: Tubelet embedding. We extract and linearly embed non-overlapping tubelets that span the spatio-temporal input volume.

ความสำคัญและประเภทของชุดข้อมูล (Importance and Types of Datasets)

- ชุดข้อมูล (Dataset) ถือเป็นองค์ประกอบหลักในงานวิจัยด้านการเรียนรู้ของเครื่อง มีหน้าที่สำคัญ 3 ประการ:
 - การฝึกสอน (Training): เป็นวัตถุดิบให้โมเดลเรียนรู้รูปแบบ (Pattern) ของท่าทางต่างๆ
 - การประเมินผล (Evaluation): ใช้วัดประสิทธิภาพและความแม่นยำของโมเดลที่ฝึกสอนแล้ว
 - การเปรียบเทียบสมรรถนะ (Benchmarking): ใช้เป็นมาตรฐานกลางสำหรับเปรียบเทียบโมเดลต่างๆ ภายใต้เงื่อนไขเดียวกัน
- ประเภทของงาน (Task) หลักในชุดข้อมูล Action Recognition:
 1. การจำแนกประเภทท่าทาง (Action Classification): กำหนด 1 ป้ายกำกับ (Label) สำหรับทั้งคลิปวิดีโอสั้นๆ ที่ถูกตัดมาเฉพาะท่าทางนั้นๆ (Trimmed clip) เช่น คลิป 10 วินาที มีป้ายกำกับว่า "กำลังเล่นกีตาร์"
 2. การระบุตำแหน่งท่าทางเชิงพื้นที่-เวลา (Spatio-temporal Action Localization): ตีกรอบ (Bounding Box) รอบบุคคลและกำหนดป้ายกำกับท่าทาง ณ เวลาใดเวลาหนึ่งในวิดีโอที่ต่อเนื่องและยังไม่ได้ตัดต่อ (Untrimmed video)



ชุดข้อมูล: Kinetics (The Kinetics Dataset)

- ชุดข้อมูล Kinetics-700
- จำนวนวิดีโอ: ประมาณ 650,000 คลิป
- ขนาด: ประกอบด้วยท่าทาง 700 ประเภท (Classes) โดยแต่ละคลิปเป็นวิดีโอสั้นๆ ความยาวประมาณ 10 วินาที ที่รวบรวมจาก YouTube
- ลักษณะเด่น:
 - เป็นชุดข้อมูลขนาดใหญ่ (Large-scale): มีความหลากหลายของท่าทางสูง ครอบคลุมกิจกรรมในชีวิตประจำวัน กีฬา และการปฏิสัมพันธ์
 - เน้นการจำแนกประเภทท่าทาง (Action Classification): คลิปวิดีโอถูกตัดต่อและตัดกรองมาอย่างดี (Cleaned and trimmed) เพื่อให้เน้นที่ท่าทางหลักเพียงอย่างเดียว
 - มีความสำคัญอย่างยิ่งสำหรับการฝึกสอนล่วงหน้า (Pre-training): โมเดลที่ทรงพลังส่วนใหญ่ในปัจจุบัน จะถูกฝึกบน Kinetics ก่อน เพื่อให้มีความเข้าใจพื้นฐานด้านการเคลื่อนไหว แล้วจึงนำไปปรับจูน (Fine-tuning) กับชุดข้อมูลเฉพาะทางที่มีขนาดเล็กกว่า



ชุดข้อมูล: AVA (The AVA Dataset)

- ชุดข้อมูล AVA: การวิเคราะห์ท่าทางในสถานการณ์จริง
- จำนวนวิดีโอ: 430 คลิปภาพยนตร์ ความยาวคลิปละ 15 นาที
- ขนาด: มีการใส่ป้ายกำกับให้กรอบรอบตัวบุคคล (Labeled bounding boxes) รวมกว่า 1.62 ล้านรายการ ครอบคลุม 80 ประเภทท่าทางพื้นฐาน (Atomic Actions)
- ลักษณะเด่น:
 - เป้าเน้นการระบุตำแหน่งท่าทางเชิงพื้นที่-เวลา (Spatio-temporal Action Localization): หมายความว่า "ใคร" ทำ "อะไร" "ที่ไหน" และ "เมื่อไหร่"
 - การใส่ป้ายกำกับแบบหนาแน่น (Dense Annotations): มีการระบุท่าทางของบุคคลทุกคนในเฟรม ทุกๆ 1 วินาที
 - รองรับหลายป้ายกำกับ (Multi-label): บุคคลหนึ่งสามารถมีหลายป้ายกำกับท่าทางได้ในเวลาเดียวกัน เช่น สามารถมีป้ายกำกับ [ยืน (stand)], [คุยกับ (talk to)], และ [มองดูบุคคลอื่น (watch person)] พร้อมกัน
 - สถานการณ์สมจริง (Realistic Scenarios): ข้อมูลมาจากคลิปภาพยนตร์ ทำให้มีความซับซ้อนของฉาก, มุมกล้อง, และปฏิสัมพันธ์ที่ใกล้เคียงกับโลกความเป็นจริง




Figure 1. The bounding box and action annotations in sample frames of the AVA dataset. Each bounding box is associated with 1 pose action (in orange), 0–3 interactions with objects (in red), and 0–3 interactions with other people (in blue). Note that some of these actions require temporal context to accurately label.





Figure 4. We show examples of how atomic actions change over time in AVA. The text shows pairs of atomic actions for the people in red bounding boxes. Temporal information is key for recognizing many of the actions and appearance can substantially vary within an action category, such as opening a door or bottle.

https://openaccess.thecvf.com/content_cvpr_2018/papers/Gu_AVA_A_Video_CVPR_2018_paper.pdf
<https://research.google.com/ava/explore.html>

ชุดข้อมูลอื่นและข้อพิจารณาในการเลือก (Other Datasets & Selection Considerations)

- ชุดข้อมูลอื่นที่สำคัญ:
 - UCF101 / HMDB51: ชุดข้อมูลยุคแรกเริ่ม มีขนาดเล็ก (ประมาณ 13,000 และ 7,000 คลิปตามลำดับ) ปัจจุบันนิยมใช้เพื่อการทดสอบแนวคิดเบื้องต้นที่ต้องการความรวดเร็วในการทดลอง
 - Something-Something V2: ประกอบด้วย 220,000 คลิป เน้นท่าทางที่ต้องอาศัยความเข้าใจความสัมพันธ์เชิงเวลาสูง (Temporal reasoning) เช่น "การผลักวัตถุจากซ้ายไปขวา" ซึ่งโมเดลไม่สามารถตอบถูกได้หากดูเพียงเฟรมเดียว
- ข้อพิจารณาในการเลือกชุดข้อมูลสำหรับโครงการ:
 - ประเภทของงาน (Task Type): ต้องการจำแนกทั้งคลิป (Classification) หรือระบุตำแหน่งบุคคลและท่าทาง (Localization)?
 - ความซับซ้อนของท่าทาง (Action Complexity): เป็นท่าทางทั่วไป (เช่น Kinetics) หรือท่าทางที่ต้องอาศัยการตีความความสัมพันธ์เชิงเวลา (เช่น Something-Something)?
 - ขอบเขตของโครงการ (Project Domain): ชุดข้อมูลที่มีอยู่สอดคล้องกับข้อมูลที่ต้องการจะนำไปใช้งานจริงหรือไม่ (เช่น การวิเคราะห์การสัมภาษณ์ อาจใกล้เคียงกับ AVA มากกว่า Kinetics)



<https://paperswithcode.com/dataset/hmdb51>



<https://paperswithcode.com/dataset/something-something-v2>

สรุปพื้นฐาน: เราได้เรียนรู้...

- แนวคิดหลักของ Action Recognition (Spatial + Temporal)
- วิวัฒนาการจาก Hand-crafted สู่ Deep Learning
- สถาปัตยกรรมหลัก: 2D-CNN+RNN, 3D-CNN, และ Vision Transformers
- **คำถามสำคัญ:** แล้วในปี 2025 มีอะไรใหม่? นักวิจัยกำลังแก้ปัญหอะไรกันอยู่?
- **ส่วนถัดไป:** 3 แนวทางวิจัยล่าสุด ที่จะเปลี่ยนวิธีที่เรามอง Action Recognition



แนวโน้มนวิจัยปัจจุบัน

ภาพรวมแนวทางการเรียนรู้ของ Action Recognition

1. การเรียนรู้แบบมีผู้สอน (Supervised Learning): แนวทางมาตรฐาน

- **วิธีการ:** โมเดลเรียนรู้จากชุดข้อมูลขนาดใหญ่ที่มี "ป้ายกำกับ" (Label) กำหนดไว้อย่างชัดเจนโดยมนุษย์ เช่น คลิปวิดีโอที่มีป้ายกำกับว่า "กำลังกระโดด" หรือ "กำลังปรบมือ"
- **ตัวอย่างชุดข้อมูล:** Kinetics , UCF101
- **ข้อจำกัด:** ต้องใช้ข้อมูลที่มีป้ายกำกับจำนวนมาก และไม่สามารถรู้จำท่าทางใหม่ที่ไม่อยู่ในชุดข้อมูลฝึกสอนได้

2. การเรียนรู้แบบกำกับตนเอง (Self-Supervised Learning): เรียนรู้โดยไม่ต้องใช้ป้ายกำกับ


- **วิธีการ:** โมเดลเรียนรู้คุณลักษณะที่สำคัญจากโครงสร้างของข้อมูลวิดีโอด้วยตัวเอง โดยไม่ต้องใช้ป้ายกำกับที่มนุษย์สร้างขึ้น
- **ตัวอย่างเทคนิค:**
 - การเติมเต็มส่วนที่หายไป (Masked AutoEncoding): เช่น VideoMAE ที่ฝึกโมเดลโดยการซ่อนส่วนใหญ่ของวิดีโอ แล้วให้โมเดลสร้างส่วนที่หายไปกลับมา
 - การเรียนรู้แบบเปรียบเทียบ (Contrastive Learning): เช่น VATT ที่เรียนรู้โดยการจับคู่ข้อมูลที่สอดคล้องกัน (เช่น วิดีโอคนปรบมือกับเสียงปรบมือ) และผลักข้อมูลที่ไม่เกี่ยวข้องกันออกจากกัน

3. การเรียนรู้โดยใช้ภาษาเป็นตัวกำกับ (Language-Supervised Learning): เรียนรู้จาก "คำอธิบาย"

- **วิธีการ:** เป็นแนวทางของ Zero-Shot Learning ที่โมเดลเรียนรู้ความเชื่อมโยงระหว่าง "ภาพในวิดีโอ" กับ "ข้อความที่อธิบายภาพนั้น" จากข้อมูลมหาศาลบนอินเทอร์เน็ต
- **ตัวอย่างเทคนิค:** CLIP และการประยุกต์ใช้กับวิดีโอ หรือโมเดลภาษา-วิดีโอขนาดใหญ่อย่าง Video-ChatGPT
- **จุดเด่น:** ไม่ได้เรียนรู้จากป้ายกำกับตายตัว แต่เรียนรู้จาก "แนวคิด" ที่สื่อผ่านภาษา ทำให้ยืดหยุ่นกว่ามาก

หัวข้อวิจัยที่ 1: การรู้จำท่าทางที่มีความละเอียดอ่อน (Fine-Grained Action Recognition)

- **ปัญหา:** โมเดลแบบดั้งเดิมเก่งในการแยกแยะท่าทางที่แตกต่างกันชัดเจน (เช่น "วิ่ง" vs "ว่ายน้ำ") แต่ยังมีปัญหาในการแยกแยะท่าทางที่คล้ายกันมาก แต่มีความหมายต่างกัน
- **เป้าหมาย:** แยกแยะความแตกต่างเล็กๆ น้อยๆ
- **ตัวอย่าง:**
 - "การพยักหน้าเห็นด้วย" vs "การพยักหน้าเพื่อรับรู้"
 - "การยิ้มอย่างจริงใจ" vs "การยิ้มตามมารยาท"
- **ความสำคัญ:** สำคัญอย่างยิ่งต่อการวิเคราะห์พฤติกรรม, บุคลิกภาพ, และปฏิสัมพันธ์ระหว่างมนุษย์



ภาพใบหน้าของคนสองคนกำลังยิ้ม

งานวิจัยสำคัญ: VideoMAE (Masked AutoEncoders)

- **แนวคิดหลัก** (การเรียนรู้แบบกำกวมดูแลตนเอง): วิธีการฝึกโมเดลโดยไม่ต้องใช้ป้ายกำกับ (Label) จำนวนมหาศาล
 - นำวิดีโอมาแบ่งเป็น "ก้อน" (Tubelets)
 - **ซ่อน (Mask)** ก้อนวิดีโอส่วนใหญ่แบบสุ่ม (สูงถึง 90%)
 - ฝึกโมเดลให้ ทำนายและสร้างส่วนที่หายไป กลับคืนมา ให้สมบูรณ์
- **ความเชื่อมโยง:** การที่โมเดลสามารถสร้างภาพการเคลื่อนไหวที่ซับซ้อนคืนมาได้จากการเห็นข้อมูลเพียงเล็กน้อย พิสูจน์ว่ามันได้เรียนรู้คุณลักษณะของการเคลื่อนไหวที่ละเอียดอ่อนอย่างแท้จริง




Figure 1: **VideoMAE** performs the task of masking random cubes and reconstructing the missing ones with an asymmetric encoder-decoder architecture. Due to high redundancy and temporal correlation in videos, we present the customized design of tube masking with an extremely high ratio (90% to 95%). This simple design enables us to create a more challenging and meaningful self-supervised task to make the learned representations capture more useful spatiotemporal structures.





Figure 2: Slowness is a general prior in (a) video data [87]. This leads to two important characteristics in time: temporal redundancy and temporal correlation. Temporal redundancy makes it possible to recover pixels under an extremely high masking ratio. Temporal correlation leads to easily reconstruct the missing pixels by finding those corresponding patches in adjacent frames under plain (b) frame masking or (c) random masking. To avoid this simple task and encourage learning representative representation, we propose a (d) tube masking, where the masking map is the same for all frames.

ผลลัพธ์และการประยุกต์ใช้ VideoMAE


- **การทดสอบ:** ประเมินผลบนชุดข้อมูลที่ต้องการความเข้าใจท่าทางละเอียดอ่อน เช่น **Something-Something V2** และชุดข้อมูลมาตรฐาน **Kinetics**
- **ผลลัพธ์:**
 - VideoMAE สร้างมาตรฐานใหม่ (State-of-the-art) บนชุดข้อมูล Something-Something V2 พิสูจน์ความสามารถในการเข้าใจท่าทางที่ซับซ้อน
 - **ประสิทธิภาพด้านข้อมูล (Data Efficiency):** เป็นจุดเด่นสำคัญ โมเดลต้องการข้อมูลที่มีป้ายกำกับในการปรับจูน (Fine-tuning) น้อยกว่าวิธีการแบบดั้งเดิม
- **การประยุกต์ใช้:** เหมาะอย่างยิ่งสำหรับงานวิเคราะห์พฤติกรรมที่ข้อมูลมีป้ายกำกับหายากหรือไม่สมบูรณ์ เพราะโมเดลสามารถเรียนรู้จากวิดีโอจำนวนมากได้ด้วยตนเอง



https://colab.research.google.com/github/huggingface/notebooks/blob/main/examples/video_classification.ipynb#scrollTo=pdxWO1qO4PTH

หัวข้อวิจัยที่ 2: การเรียนรู้แบบหลายรูปแบบ (Multi-modal Learning)

- **แนวคิด:** พฤติกรรมของมนุษย์ไม่ได้แสดงออกผ่านภาพเพียงอย่างเดียว แต่ยังรวมถึง **น้ำเสียง (Audio)** และ **คำพูด (Text)** ด้วย
- **Multi-modal Learning** คือการสร้างโมเดลที่สามารถรับข้อมูลจากหลายแหล่ง และหลอมรวมข้อมูลเหล่านั้นเข้าด้วยกันเพื่อการตัดสินใจที่แม่นยำยิ่งขึ้น
- **ตัวอย่าง:** การพูดว่า "ฉันสบายดี" ด้วยน้ำเสียงสั่นเครือและหลบสายตา ให้ข้อมูลที่ขัดแย้งกันซึ่งโมเดลต้องเรียนรู้ที่จะตีความ
- **ความเชื่อมโยงกับสไลด์ AVA:** ชุดข้อมูล AVA แสดงให้เห็นท่าทางที่ซับซ้อน เช่น "คุยกับ" (talk to) หรือ "ฟัง" (listen to) ซึ่งการมีข้อมูลเสียงและข้อความจะช่วยให้โมเดลแยกแยะได้อย่างแม่นยำยิ่งขึ้น



งานวิจัย : VATT (Video-Audio-Text Transformer)

- แนวคิดหลัก:
 - พัฒนา Transformer เดียว ที่สามารถเรียนรู้จากข้อมูล 3 รูปแบบได้พร้อมกัน โดยใช้สถาปัตยกรรม Transformer
 - วิธีการ (Contrastive Learning): โมเดลจะเรียนรู้จากการจับคู่ข้อมูลที่ถูกต้อง (เช่น วิดีโอคนปรบมือคู่กับเสียงปรบมือ) และผลักข้อมูลที่ไม่เข้าคู่กันออกจากกัน
- เป้าหมาย: สร้าง "ตัวแทนข้อมูล" (Representation) ที่เป็นหนึ่งเดียวและมีความหมาย สามารถนำไปประยุกต์ใช้ได้กับงานหลากหลายประเภท




Figure 1: **Overview of the VATT architecture and the self-supervised, multimodal learning strategy.** VATT linearly projects each modality into a feature vector and feeds it into a Transformer encoder. We define a semantically hierarchical common space to account for the granularity of different modalities and employ the Noise Contrastive Estimation (NCE) to train the model.

METHOD	Kinetics-400		Kinetics-600		Moments in Time		TFLOPs
	Top-1	Top-5	Top-1	Top-5	Top-1	Top-5	
I3D [13]	71.1	89.3	71.9	90.1	29.5	56.1	-
R(2+1)D [26]	72.0	90.0	-	-	-	-	17.5
bLVNet [27]	73.5	91.2	-	-	31.4	59.3	0.84
S3D-G [96]	74.7	93.4	-	-	-	-	-
Oct-I3D+NL [20]	75.7	-	76.0	-	-	-	0.84
D3D [83]	75.9	-	77.9	-	-	-	-
I3D+NL [93]	77.7	93.3	-	-	-	-	10.8
ip-CSN-152 [87]	77.8	92.8	-	-	-	-	3.3
AttentionNAS [92]	-	-	79.8	94.4	32.5	60.3	1.0
AssembleNet-101 [77]	-	-	-	-	34.3	62.7	-
MoViNet-A5 [47]	78.2	-	82.7	-	39.1	-	0.29
LGD-3D-101 [69]	79.4	94.4	81.5	95.6	-	-	-
SlowFast-R101-NL [30]	79.8	93.9	81.8	95.1	-	-	7.0
X3D-XL [29]	79.1	93.9	81.9	95.5	-	-	1.5
X3D-XXL [29]	80.4	94.6	-	-	-	-	5.8
TimeSFormer-L [9]	80.7	94.7	82.2	95.6	-	-	7.14
VATT-Base	79.6	94.9	80.5	95.5	38.7	67.5	9.09
VATT-Medium	81.1	95.6	82.4	96.1	39.5	68.2	15.02
VATT-Large	82.1	95.5	83.6	96.6	41.1	67.7	29.80
VATT-MA-Medium	79.9	94.9	80.8	95.5	37.8	65.9	15.02

Table 1: Video action recognition accuracy on Kinetics-400, Kinetics-600, and Moments in Time.

ผลลัพธ์และการประยุกต์ใช้ VATT

- การทดสอบ: ประเมินผลกับงานหลากหลายประเภท (Downstream tasks) เช่น:
 - Action Recognition: บนชุดข้อมูล Kinetics
 - Audio Classification: บนชุดข้อมูล AudioSet
 - Text-to-Video Retrieval: การค้นหาวิดีโอจากข้อความ
- ผลลัพธ์: VATT
 - มีประสิทธิภาพสูงในทุกประเภทของงาน พิสูจน์ให้เห็นว่าตัวแทนข้อมูลที่เรียนรู้มา มีความยืดหยุ่นและนำไปใช้ได้กว้างขวาง
 - ในงาน Action Recognition โมเดล VATT สามารถทำคะแนนได้ดีเทียบเท่าหรือดีกว่าโมเดลที่ฝึกสอนด้วยภาพเพียงอย่างเดียว
- การประยุกต์ใช้: เหมาะกับงานวิเคราะห์การสัมภาษณ์ หรือ การปฏิสัมพันธ์ที่ต้องอาศัยการตีความทั้งภาพ (ภาษากาย) และเสียง (น้ำเสียง, คำพูด) ประกอบกัน

METHOD	mAP	AUC	d-prime
DaiNet [21]	29.5	95.8	2.437
LeeNet11 [55]	26.6	95.3	2.371
LeeNet24 [55]	33.6	96.3	2.525
Res1dNet31 [49]	36.5	95.8	2.444
Res1dNet51 [49]	35.5	94.8	2.295
Wavegram-CNN [49]	38.9	96.8	2.612
VATT-Base	39.4	97.1	2.895
VATT-MA-Medium	39.3	97.0	2.884

Table 2: Finetuning results for AudioSet event classification.

METHOD	PRE-TRAINING DATA	TOP-1	TOP-5
iGPT-L [16]	ImageNet	72.6	-
ViT-Base [25]	JFT	79.9	-
VATT-Base	-	64.7	83.9
VATT-Base	HowTo100M	78.7	93.9

Table 3: Finetuning results for ImageNet classification.

METHOD	BATCH	EPOCH	YouCook2		MSR-VTT	
			R@10	MedR	R@10	MedR
MIL-NCE [59]	8192	27	51.2	10	32.4	30
MMV [1]	4096	8	45.4	13	31.1	38
VATT-MBS	2048	4	45.5	13	29.7	49
VATT-MA-Medium	2048	4	40.6	17	23.6	67

Table 4: Zero-shot text-to-video retrieval.




Figure 2: t-SNE visualization of the feature representations extracted by the vision Transformer in different training settings. For better visualization, we show 100 random classes from Kinetics-400.




Figure 3: t-SNE visualization and distribution of pair-wise similarities of the input space vs. output space for modality-specific and modality-agnostic backbones when different modalities are fed.

งานวิจัย : Video-ChatGPT และ Video-Language Models

- **แนวคิดหลัก:** การผสมผสาน Large Language Models เข้ากับความเข้าใจวิดีโอ เพื่อให้ AI สามารถสนทนาเกี่ยวกับเนื้อหาในวิดีโอได้อย่างธรรมชาติ



- **ความก้าวหน้าจาก CLIP และ VATT:** แทนที่จะแค่จับคู่วิดีโอกับข้อความ Video-ChatGPT สามารถตอบคำถามแบบโต้ตอบเกี่ยวกับรายละเอียดในวิดีโอได้
- **สถาปัตยกรรม:** ใช้ Video Encoder ร่วมกับ Large Language Model (LLaMA) โดยมี Video Adapter เป็นตัวเชื่อมระหว่างโมดูล
- **ความสามารถ:** อธิบายการกระทำที่ซับซ้อน วิเคราะห์ความสัมพันธ์เชิงเวลา และตอบคำถามเกี่ยวกับเหตุและผลของการกระทำในวิดีโอ
- **การประยุกต์ใช้:** เหมาะสำหรับการวิเคราะห์การสัมภาษณ์แบบโต้ตอบ การสร้างคำบรรยายวิดีโอโดยอัตโนมัติ และการช่วยเหลือผู้พิการทางสายตา

<https://github.com/mbzuai-oryx/Video-ChatGPT>

หัวข้อวิจัยที่ 3: การเรียนรู้แบบไม่มีตัวอย่าง (Zero-Shot & Few-Shot Learning)

- **ปัญหา:** โมเดลส่วนใหญ่ต้องการตัวอย่างจำนวนมากสำหรับแต่ละท่าทางที่จะเรียนรู้ จะทำอย่างไรหากเราต้องการให้โมเดลรู้จักท่าทางใหม่ๆ ที่ไม่เคยเห็นในชุดข้อมูลฝึกสอน?
- **แนวคิด:**
 - **Zero-Shot Learning:** ทำให้โมเดลสามารถรู้จำท่าทางที่ไม่เคยเห็นมาก่อน โดยอาศัยเพียง "คำอธิบาย" ของท่าทางนั้นๆ (เช่น การใช้ข้อมูล Text)
 - **Few-Shot Learning:** ทำให้โมเดลสามารถเรียนรู้ท่าทางใหม่จากตัวอย่างเพียงไม่กี่ตัวอย่าง (1-5 ตัวอย่าง)
- **ความสำคัญ:** เพิ่มความยืดหยุ่นและขยายขีดความสามารถของโมเดลให้สามารถรับมือกับสถานการณ์ในโลกจริงที่มีความหลากหลายและคาดเดาไม่ได้

Traditional Supervised Learning



Few-Shot Learning



Zero-Shot Learning



งานวิจัยสำคัญ: CLIP และการประยุกต์ใช้กับวิดีโอ

- แนวคิดหลัก: CLIP ถูกฝึกบนคู่รูปภาพและข้อความกว่า 400 ล้านคู่จากอินเทอร์เน็ต เพื่อเรียนรู้ความเชื่อมโยงระหว่าง "ภาพ" และ "ข้อความที่อธิบายภาพนั้น"
- การประยุกต์ใช้กับวิดีโอ (Video-CLIP):
 - สามารถนำหลักการของ CLIP มาปรับใช้เพื่อทำ Zero-Shot Action Recognition ได้
 - วิธีการ: แทนที่จะให้โมเดลเลือกระหว่างป้ายกำกับที่กำหนดไว้ล่วงหน้า เราสามารถถามโมเดลได้ว่า "วิดีโอนี้ตรงกับคำอธิบายว่า 'a person waving goodbye' หรือ 'a person clapping hands' มากกว่ากัน?"




Figure 1. Summary of our approach. While standard image models jointly train an image feature extractor and a linear classifier to predict some label, CLIP jointly trains an image encoder and a text encoder to predict the correct pairings of a batch of (image, text) training examples. At test time the learned text encoder synthesizes a zero-shot linear classifier by embedding the names or descriptions of the target dataset's classes.

สรุปส่วนที่ 2

- สรุป 3 แนวทางวิจัย :
 - Fine-Grained (VideoMAE): เรียนรู้การเคลื่อนไหวที่ละเอียดอ่อนโดยการ "เติมส่วนที่หายไป" ของวิดีโอ
 - Multi-modal (VATT): สร้างความเข้าใจที่เป็นหนึ่งเดียวจากการหลอมรวมข้อมูลภาพ เสียง และข้อความ
 - Zero-Shot (CLIP): ทำให้โมเดลสามารถรู้จำท่าทางใหม่ๆ ที่ไม่เคยเห็นมาก่อนโดยใช้คำอธิบาย
- ภาพรวม: แนวโน้มมุ่งสู่การสร้างโมเดลที่ เรียนรู้ได้ด้วยตนเองมากขึ้น (Self-supervised), เข้าใจข้อมูลได้รอบด้านขึ้น (Multi-modal), และ มีความยืดหยุ่นสูงขึ้น (Zero-shot) เพื่อให้เข้าใจความสามารถในการเข้าใจโลกของมนุษย์


การประยุกต์ใช้และแนวโน้มอนาคต

วิธีการใดคือ State-of-the-Art ในปัจจุบัน?

- สำหรับงานที่ต้องการความเข้าใจการเคลื่อนไหวที่ละเอียดอ่อนและมีข้อมูลกำกับจำกัด:
 - แนวทางที่แนะนำ: Masked Autoencoders (เช่น VideoMAE)
 - เหตุผล: มีความสามารถสูงในการเรียนรู้คุณลักษณะการเคลื่อนไหวที่ซับซ้อนโดยไม่ต้องพึ่งพาป้ายกำกับ (Self-supervised) ทำให้เป็นจุดเริ่มต้นที่ทรงพลังอย่างยิ่งก่อนนำไปปรับจูน (Fine-tuning) กับข้อมูลเฉพาะทาง
- สำหรับงานที่ต้องการการตีความพฤติกรรมมนุษย์ที่ซับซ้อนและมีข้อมูลหลายรูปแบบ:
 - แนวทางที่แนะนำ: Multi-modal Transformers (เช่น VATT)
 - เหตุผล: สามารถรวมข้อมูลจากภาพ (ภาษากาย), เสียง (น้ำเสียง), และข้อความ (คำพูด) เพื่อสร้างความเข้าใจที่เป็นหนึ่งเดียวและลึกซึ้งกว่าเหมาะสมอย่างยิ่งสำหรับวิเคราะห์การปฏิสัมพันธ์ที่ต้องอาศัยการตีความหลายมิติพร้อมกัน
- สำหรับงานที่ต้องการความยืดหยุ่นสูงสุดและต้องการวิเคราะห์แนวคิดที่เป็นนามธรรม:
 - แนวทางที่แนะนำ: Large Video-Language Models (เช่น Video-ChatGPT, Video-CLIP)
 - เหตุผล: เป็นการใช้ความสามารถของ Zero-Shot Learning ทำให้เราสามารถ "สืบค้น" หรือ "ถาม" เกี่ยวกับพฤติกรรมที่ซับซ้อนด้วยภาษาธรรมชาติได้ โดยไม่จำเป็นต้องสร้างชุดข้อมูลสำหรับทุกพฤติกรรมที่ต้องการวิเคราะห์

การประเมินผลโมเดล (How to Evaluate a Model?)

- ตัวชี้วัดและข้อพิจารณาในการประเมินสมรรถนะ
 - โมเดลเมื่ออ่านงานวิจัย เราจะทราบได้อย่างไรว่าโมเดลใดมีประสิทธิภาพดีกว่ากัน? เราจำเป็นต้องพิจารณาจากตัวชี้วัดที่เป็นมาตรฐาน:
- ตัวชี้วัดสำหรับงานจำแนกประเภท (Classification Metrics):
 - Top-1 Accuracy: ความแม่นยำที่โมเดลทายคำตอบอันดับแรกได้ถูกต้อง
 - Top-5 Accuracy: ความแม่นยำที่หนึ่งในห้าคำตอบแรกของโมเดลมีคำตอบที่ถูกต้องอยู่
- ตัวชี้วัดสำหรับงานระบุตำแหน่ง (Localization Metrics):
 - mAP (mean Average Precision): เป็นตัวชี้วัดมาตรฐานสำหรับชุดข้อมูลอย่าง AVA ซึ่งไม่เพียงวัดความถูกต้องของการทายประเภทท่าทาง แต่ยังวัดความแม่นยำของตำแหน่งกรอบสี่เหลี่ยม (Bounding Box) เทียบกับข้อมูลจริง (Ground Truth) ด้วย
- ข้อควรพิจารณาเพิ่มเติม:
 - ต้นทุนการคำนวณ (Computational Cost): วัดจาก FLOPs (Floating Point Operations per Second) และจำนวนพารามิเตอร์ (Parameters) โมเดลที่แม่นยำสูงแต่ช้า อาจไม่เหมาะกับการใช้งานจริง
 - ชุดข้อมูลที่ใช้ทดสอบ (Benchmark Dataset): ผลลัพธ์จะน่าเชื่อถือก็ต่อเมื่อทดสอบบนชุดข้อมูลมาตรฐานที่เป็นที่ยอมรับ



แหล่งค้นคว้าข้อมูลคุณภาพสูง (Where to Find High-Quality Research)

1. **Google Scholar:** เครื่องมือค้นหาค้นหาบทความทางวิชาการที่ครอบคลุมที่สุด สามารถตั้งค่าการแจ้งเตือน (Alerts) สำหรับคำสำคัญ (Keywords) ที่สนใจได้ (<https://scispace.com/>, <https://www.semanticscholar.org/>)

2. **arXiv.org (อ่านว่า อาร์ไคฟ์):** แหล่งรวมงานวิจัยฉบับร่าง (Pre-prints) ทำให้เข้าถึงแนวคิดและผลการทดลองใหม่ล่าสุดได้ก่อนที่จะผ่านการทบทวนและตีพิมพ์ในวารสาร

3. **แหล่งรวมบทความจากงานประชุมวิชาการ (Conference Proceedings):**

CVF (Computer Vision Foundation): สำหรับงานประชุมชั้นนำด้าน Computer Vision เช่น CVPR, ICCV, ECCV

IEEE Xplore: สำหรับวารสารและงานประชุมวิชาการของสถาบันวิชาชีพวิศวกรรมไฟฟ้าและอิเล็กทรอนิกส์

4. **Papers with Code:** แพลตฟอร์มที่เชื่อมโยงบทความวิจัยเข้ากับโค้ดที่นักวิจัยเผยแพร่ พร้อมทั้งแสดงตารางอันดับ (Leaderboards) เปรียบเทียบประสิทธิภาพของโมเดลต่างๆ บนชุดข้อมูลมาตรฐาน

Action Recognition In Videos

70 papers with code • 17 benchmarks • 17 datasets

Action Recognition in Videos is a task in computer vision and pattern recognition where the goal is to identify and categorize human actions performed in a video sequence. The task involves analyzing the spatiotemporal dynamics of the actions and mapping them to a predefined set of action classes, such as running, jumping, or swimming.

Benchmarks

These leaderboards are used to track progress in Action Recognition In Videos

Trend	Dataset	Best Model	Paper	Code	Compare
	Jester (Gesture Recognition)	CPNet Res34, 5 CP			See all
	UCF101	STM (ImageNet+Kinetics pretrain)			See all
	PKU-MMD	DSCNet (RGB + Pose)			See all
	Something-Something V2	CAST-B/16			See all
	Something-Something V1	STM (16 frames, ImageNet pretraining)			See all
	Kinetics-400	Florence			See all
	Sports-1M	G-Blend			See all
	FS-Something-Something V2-Small	ITANet			See all
	FS-Something-Something V2-Full	ITANet			See all
	THUMOS'14	Single-stream R-C3D (two-way buffer)			See all

Show all 17 benchmarks

Edit


Content

- Introduction
- Benchmarks
- Datasets
- Subtasks
- Libraries
- Papers
 - Most implemented
 - Social
 - Latest
 - No code

<https://paperswithcode.com/task/action-recognition-in-videos-2#benchmarks>

วิธีการอ่านงานวิจัยอย่างมีประสิทธิภาพ (How to Read a Paper Effectively)

- เทคนิคการอ่านบทความวิจัยแบบ Three-Pass Approach
 - เป็นแนวทางที่ได้รับการยอมรับในการอ่านบทความวิจัยอย่างเป็นระบบ ไม่จำเป็นต้องอ่านทุกตัวอักษรในครั้งแรก
- Pass 1 (5-10 นาที): ภาพรวม (The Bird's-Eye View)
 - อ่านชื่อเรื่อง (Title), บทคัดย่อ (Abstract), และบทสรุป (Conclusion)
 - ดูรูปภาพ ตาราง และกราฟทั้งหมด เพื่อทำความเข้าใจแนวคิดและผลลัพธ์หลัก
 - เป้าหมาย: ตัดสินใจว่าบทความนี้เกี่ยวข้องและควรค่าแก่การอ่านต่อหรือไม่
- Pass 2 (ประมาณ 1 ชั่วโมง): ทำความเข้าใจเนื้อหาหลัก
 - อ่านบทนำ (Introduction) และผลการทดลอง (Results) อย่างละเอียด แต่สามารถข้ามส่วนคณิตศาสตร์ที่ซับซ้อนในส่วนวิธีการ (Methodology) ไปก่อน
 - เป้าหมาย: ทำความเข้าใจปัญหาที่บทความต้องการแก้ไข, แนวทางที่นำเสนอ, และผลลัพธ์ที่ได้
- Pass 3 (สำหรับบทความที่สำคัญมาก): อ่านเชิงลึก
 - อ่านบทความทั้งฉบับอย่างละเอียด รวมถึงสมการคณิตศาสตร์ พยายามทำความเข้าใจสมมติฐานและข้อจำกัดของงานวิจัย
 - เป้าหมาย: สามารถวิเคราะห์และนำเสนอแนวคิดของบทความใหม่ได้ หรือนำไปต่อยอดได้



<https://medium.com/@cindy.liangyy/reading-papers-efficiently-with-the-three-pass-approach-a48ee8c940e>

การเลือกวิธีการให้เหมาะกับโจทย์ (Choosing the Right Method)

กรอบแนวคิดในการเลือกสถาปัตยกรรมสำหรับโครงการ

- สรุปเป็นคำถามสำคัญเพื่อช่วยในการตัดสินใจเลือกวิธีการที่เหมาะสมได้ดังนี้
- 1. ประเภทของงานคืออะไร?
 - Classification (ทั้งคลิปมี 1 ท่าทาง) → พิจารณา 3D CNN, Video Transformers
 - Localization (ระบุตำแหน่งคนและท่าทาง) → ต้องใช้โมเดลที่ออกแบบมาสำหรับงานนี้โดยเฉพาะ ซึ่งมักต่อยอดมาจาก Object Detector
- 2. ลักษณะของท่าทางเป็นอย่างไร?
 - ท่าทางทั่วไป (General Actions) → โมเดลมาตรฐานเช่น I3D อาจเพียงพอ
 - ท่าทางละเอียดอ่อน / ต้องการความเข้าใจเชิงเวลา (Fine-grained / Temporal) → พิจารณา Video Transformers, VideoMAE
- 3. มีข้อมูลรูปแบบอื่นหรือไม่?
 - มีข้อมูลเสียงและข้อความประกอบ → พิจารณาแนวทาง Multi-modal เช่น VATT เพื่อเพิ่มความแม่นยำ
- 4. ข้อจำกัดด้านทรัพยากรเป็นอย่างไร?
 - ต้องการความเร็วในการทำงานสูง / ใช้งานบนอุปกรณ์ขนาดเล็ก → พิจารณาโมเดลที่มีค่า FLOPs และจำนวน Parameters ต่ำ

จริยธรรมใน AI: ความลำเอียงและความเป็นธรรม (AI Ethics: Bias and Fairness)

- ความท้าทายด้านความลำเอียงในข้อมูล (Data Bias)
- หลักการพื้นฐาน: โมเดลปัญญาประดิษฐ์เรียนรู้และสะท้อนรูปแบบจากข้อมูลที่ใช้ฝึกสอน หากข้อมูลมีความลำเอียง โมเดลก็จะมี ความลำเอียงไปด้วย
- ตัวอย่างความลำเอียง:
 - ความลำเอียงทางประชากร (Demographic Bias): ชุดข้อมูลขนาดใหญ่เช่น Kinetics มักรวบรวมวิดีโอจากประเทศตะวันตกเป็นหลัก ทำให้โมเดลอาจทำงานได้ไม่ดีกับบริบททางวัฒนธรรมหรือลักษณะทางกายภาพของคนในภูมิภาคอื่น
 - ความลำเอียงจากทัศนคติเหมารวม (Stereotypical Bias): หากข้อมูลที่ใช้ฝึกมีภาพผู้หญิงทำอาหารและผู้ชายเล่นฟุตบอลเป็นส่วนใหญ่ โมเดลอาจเรียนรู้ความสัมพันธ์ที่เหมารวมเหล่านี้ ซึ่งเป็นอันตรายอย่างยิ่งในการนำไปใช้วิเคราะห์บุคลิกภาพหรือความสามารถ
- ผลกระทบ: การตัดสินใจที่ไม่เป็นธรรม, การกีดกัน, และการตอกย้ำอคติทางสังคม



ใบหน้าของผู้คนจากหลากหลายเชื้อชาติ เพศ และวัย

สรุปและทิศทางในอนาคต (Summary & Future Directions)

- สรุปประเด็นสำคัญ

- วิวัฒนาการจากสถาปัตยกรรมยุคบุกเบิก (2D/3D CNN) สู่ยุคของ Vision Transformers
- แนวโน้มการวิจัยมุ่งสู่การเรียนรู้ที่ละเอียดอ่อน (Fine-grained), รอบด้าน (Multi-modal), และ พึ่งพาตนเองได้มากขึ้น (Self-supervised)
- การเลือกใช้เครื่องมือ (ชุดข้อมูล, ตัวชี้วัด) และการคำนึงถึงมิติทางจริยธรรม เป็นสิ่งสำคัญอย่างยิ่ง

- ทิศทางในอนาคตที่น่าจับตา:

- **Embodied AI:** ปัญญาประดิษฐ์ที่ไม่ได้อยู่แค่ในคอมพิวเตอร์ แต่ฝังอยู่ในหุ่นยนต์ที่สามารถเข้าใจและโต้ตอบกับการกระทำของมนุษย์ในโลกจริง
- **AI-driven Data Synthesis:** การใช้ Generative AI เช่น Diffusion Model เพื่อสังเคราะห์ข้อมูลวิดีโอที่หลากหลายสำหรับการฝึกสอน เพื่อลดปัญหาความลำเอียง
- **Neuro-Symbolic AI:** การผสมผสานการเรียนรู้เชิงลึกเข้ากับการให้เหตุผลเชิงสัญลักษณ์ เพื่อให้ AI เข้าใจ "เหตุและผล" ของการกระทำ ไม่ใช่แค่การจดจำรูปแบบ

